

機器學習數學


鄭宇倫

人工智慧的演進與核心


人工智慧

- 目標：在沒遇過的情況下，做出預測或決策
- 形式：模型（超級函數 $F(x) = y$ ）
- 方法：

	特徵	規則	核心概念	範例
傳統程式設計	人設計	人設計	If-else 條件判斷	出現「中獎」就是垃圾信
傳統機器學習	人設計	機器學	特徵工程、統計模型	計算驚嘆號數量、大寫比例
深度學習	機器學	機器學	端到端學習、神經網路	直接給原始信件、對應分類



深度學習簡介



AI 工程師定位

	<u>AI 賦能者</u>	<u>AI 應用開發者</u>	<u>AI 模型工程師</u>
工作內容	● 使用 AI 提升個人 / 團隊生產力	● 建立 AI 產品與服務	● 建立、優化 AI 模型
需要理解	● AI 如何使用	● AI 如何整合	● AI 如何運作
常用技術	● AI Coding、AI 工具導入	● API、Agent、Tool、Skill、RAG	● 選型、訓練、部署、優化
核心問題	● 如何讓 AI 回答比較好	● 如何讓 AI 完成工作	● 如何讓 AI 更準、更有效率

AI 實務與底層原理

	<u>直覺做法</u>	<u>嚴謹做法（理解原理）</u>	<u>實務案例分享</u>
硬體與引擎選擇	● 能跑出結果	● 依照運算特性選擇硬體與引擎	● Mac vs. NVIDIA Ollama vs. vLLM
推論加速	● 能加速即可	● 知道加速的代價	● MTP 用更多 VRAM、不影響生成品質
訓練資源	● VRAM 不夠就是不夠	● 知道 VRAM 花在哪、如何優化	● LoRA 學習幅度有限、檢查點用時間換空間
標註策略	● 看起來合理	● 知道模型可能走捷徑、資料可能干擾模型	● 資料收集多樣性、負片影像影響學習

目次

Ch 1. 線性代數

1. 向量
2. 內積
3. 矩陣
4. 語言模型運作

Ch 2. 微分

1. 深度學習優化策略
2. 微分
3. 偏微分與梯度
4. 連鎖律
5. 反向傳播
6. 記憶體管理

Ch 3. 統計

1. 數據輪廓
2. 模型評估
3. 資訊理論

Chapter 1.

線性代數

1. 向量
2. 內積
3. 矩陣
4. 語言模型運作

Section 1.


向量

1. 向量與空間
2. 線性組合與 Span
3. 子空間
4. 線性獨立與基底

向量 - 幾何觀點

向量


- 定義：有方向的量




$\Rightarrow$ 可假設所有向量起點相同

- 運算

- 加法：對於任意向量 v , w , 可得向量 $v + w$



- 係數積（純量乘法）：對於任意向量 v 、任意實數 c , 可得向量 $c \cdot v$




實數包含 0 、 3 、 -0.86 、 $\frac{11}{7}$ 、 $\sqrt[3]{2}$ 、 π 等
不含 $i = \sqrt{-1}$

向量運算 - 代數性質

向量性質

● 加法


零向量	$\vec{0} + v = v + \vec{0} = v$
反元素	$-v + v = v + (-v) = \vec{0}$
結合律	$u + (v + w) = (u + v) + w$
交換律	$u + v = v + u$



減法： $v - w = v + (-1) \cdot w$


● 係數積

單位元素	$1 \cdot v = v$
向量加法分配律	$c \cdot (v + w) = c \cdot v + c \cdot w$
係數加法分配律	$(a + b) \cdot v = a \cdot v + b \cdot v$
乘法相容	$(a * b) \cdot v = a \cdot (b \cdot v)$




座標表示法

- 想法：以一組固定的向量為基準，
將所有向量表示為該基準的組合
- 把係數寫成「行向量」(column vector)



$$\begin{aligned} v + w &= (3 \cdot e_1 + 2 \cdot e_2) + (4 \cdot e_1 + (-1) \cdot e_2) \\ &= (3 \cdot e_1 + 4 \cdot e_1) + (2 \cdot e_2 + (-1) \cdot e_2) \\ &= 7 \cdot e_1 + 1 \cdot e_2 \end{aligned}$$

笛卡兒座標系



- 代數表示法：
 - 若 $v = v_1 \cdot e_1 + v_2 \cdot e_2$ ，則寫為 $\begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$
- 運算代數化：
 - 加法： $\begin{bmatrix} v_1 \\ v_2 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} v_1 + w_1 \\ v_2 + w_2 \end{bmatrix}$
 - 係數積： $c \cdot \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} c \cdot v_1 \\ c \cdot v_2 \end{bmatrix}$

資料與 Column Vector

No.	BMI	體脂率	全馬完賽時間
1	21	15%	3:20
2	23	19%	4:10
3	26	24%	5:15

- $\begin{bmatrix} 21 \\ 15 \end{bmatrix}, \begin{bmatrix} 23 \\ 19 \end{bmatrix}, \begin{bmatrix} 26 \\ 24 \end{bmatrix} \in \text{二維空間 (平面)} = \mathbb{R}^2 = \mathbb{R} \times \mathbb{R} = (\mathbb{R}, \mathbb{R})$

No.	BMI	體脂率	靜態心率	跑齡	月跑量	時間
1	21	15%	52	5	250	3:20
2	23	19%	58	3	160	4:10
3	26	24%	65	2	80	5:15

- $\begin{bmatrix} 21 \\ 15 \\ 52 \\ 5 \\ 250 \end{bmatrix}, \begin{bmatrix} 23 \\ 19 \\ 58 \\ 3 \\ 160 \end{bmatrix}, \begin{bmatrix} 26 \\ 24 \\ 65 \\ 2 \\ 80 \end{bmatrix} \in \mathbb{R}^5$

$$\text{加法: } \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} + \begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix} = \begin{bmatrix} v_1 + w_1 \\ \vdots \\ v_n + w_n \end{bmatrix}$$

$$\text{係數積: } c \cdot \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} c \cdot v_1 \\ \vdots \\ c \cdot v_n \end{bmatrix}$$

向量空間

向量空間

(Vector space)

- 概念：向量活動的完整空間，如 $\mathbb{R}^n$ ，其中 $n = 1, 2, \dots$

- 對於同一空間中的向量，不論如何相加、縮放，都仍在該空間中

若 $v, w \in \mathcal{V}$ 則 $c_1 \cdot v + c_2 \cdot w \in \mathcal{V}$

- 空間中的所有成員都具備相同結構

若 $v, w \in \mathcal{V}$ ，且 $v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$ ，則 $w = \begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix}$

$$\text{加法：} \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} + \begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix} = \begin{bmatrix} v_1 + w_1 \\ \vdots \\ v_n + w_n \end{bmatrix}$$

$$\text{係數積：} c \cdot \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} c \cdot v_1 \\ \vdots \\ c \cdot v_n \end{bmatrix}$$

例： $\begin{bmatrix} 21 \\ 15 \end{bmatrix} \in \mathbb{R}^2$; $\begin{bmatrix} 21 \\ 15 \\ 0 \\ 0 \\ 0 \end{bmatrix} \in \mathbb{R}^5$

```
import numpy as np
```

```
a = np.array([1, 2, 0])           # shape (3,)
```

```
b = np.array([1, 2])             # shape (2,)
```

```
a + b
```

```
-----  
ValueError: operands could not be broadcast together with shapes (3,) (2,)
```

線性組合

線性組合

(Linear combination)

- 定義：若 $v_1, v_2, \dots, v_n$ 是向量， $c_1, c_2, \dots, c_n$ 是純量（實數），
且向量 $v = c_1 \cdot v_1 + c_2 \cdot v_2 + \dots + c_n \cdot v_n$ ，
則 v 被稱為 $v_1, v_2, \dots, v_n$ 的線性組合

線性組合 = 加權合 (weighted sum)

- 若 $v_1 = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$ 、 $v_2 = \begin{bmatrix} 4 \\ -1 \end{bmatrix}$ ，則 $w = \begin{bmatrix} 0 \\ -11 \end{bmatrix} = -4 \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix} + 3 \cdot \begin{bmatrix} 4 \\ -1 \end{bmatrix}$ 是 v_1, v_2 的線性組合


- 若 $v_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$ 、 $v_2 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ ，則 $\begin{bmatrix} 2 \\ 5 \\ 5 \end{bmatrix} = -3 \cdot \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + 5 \cdot \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ 是 v_1, v_2 的線性組合

則 $\begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix}$ 不是 v_1, v_2 的線性組合

Span - 幾何直觀


Span • 定義： $\text{Span}\{v_1, v_2, \dots, v_n\} = \{v_1, v_2, \dots, v_n \text{ 的所有線性組合}\}$
 $= \{\text{所有可能的 } c_1 \cdot v_1 + c_2 \cdot v_2 + \dots + c_n \cdot v_n\}$

• $\text{Span}\left\{\begin{bmatrix} 2 \\ 1 \end{bmatrix}\right\} = \left\{c \cdot \begin{bmatrix} 2 \\ 1 \end{bmatrix}\right\} = \left\{\begin{bmatrix} 2c \\ c \end{bmatrix}\right\}$



$= \text{Span}\left\{\begin{bmatrix} -4 \\ -2 \end{bmatrix}\right\} = \text{Span}\left\{\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} -4 \\ -2 \end{bmatrix}\right\}$


• $\text{Span}\left\{\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix}\right\} = \left\{\begin{bmatrix} 2a + b \\ a - b \end{bmatrix}\right\}$



$\mathbb{R}^2$ 空間的 Span

Span • 定義： $\text{Span}\{v_1, v_2, \dots, v_n\} = \{v_1, v_2, \dots, v_n \text{ 的所有線性組合}\}$
 $= \{\text{所有可能的 } c_1 \cdot v_1 + c_2 \cdot v_2 + \dots + c_n \cdot v_n\}$

- $\text{Span}\left\{\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix}\right\} = \text{整個二維平面} = \mathbb{R}^2 = \mathbb{R} \times \mathbb{R}$
 $= (\mathbb{R}, \mathbb{R})$



- 證明：從 $\mathbb{R}^2$ 任選向量 $\begin{bmatrix} c \\ d \end{bmatrix}$ ，證明 $\begin{bmatrix} c \\ d \end{bmatrix}$ 屬於 $\text{Span}\left\{\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix}\right\}$

$$\begin{bmatrix} c \\ d \end{bmatrix} = a \begin{bmatrix} 2 \\ 1 \end{bmatrix} + b \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 2a + b \\ a - b \end{bmatrix} \Rightarrow \begin{cases} 2a + b = c \\ a - b = d \end{cases} \Rightarrow \begin{cases} a = \frac{c + d}{3} \\ b = \frac{c - 2d}{3} \end{cases}$$

- 任兩不平行向量，皆可 Span 出 $\mathbb{R}^2$

Span 時的多餘向量


Span • 定義： $\text{Span}\{v_1, v_2, \dots, v_n\} = \{v_1, v_2, \dots, v_n \text{ 的所有線性組合}\}$
 $= \{\text{所有可能的 } c_1 \cdot v_1 + c_2 \cdot v_2 + \dots + c_n \cdot v_n\}$

• $\text{Span}\left\{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}\right\} : \mathbb{R}^3 \text{ 中的二維平面}$

$$= \text{Span}\left\{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix}\right\} = \text{Span}\left\{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}\right\}$$

拿掉任一向量也不影響 Span

有一個沒貢獻、是多餘的



「多餘向量」的幾何特性



Span • 定義： $\text{Span}\{v_1, v_2, \dots, v_n\} = \{v_1, v_2, \dots, v_n \text{ 的所有線性組合}\}$
 $= \{\text{所有可能的 } c_1 \cdot v_1 + c_2 \cdot v_2 + \dots + c_n \cdot v_n\}$

- $\text{Span}\left\{\begin{bmatrix} 2 \\ 1 \end{bmatrix}\right\} = \text{Span}\left\{\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} -4 \\ -2 \end{bmatrix}\right\}$

➤ 觀察： $\begin{bmatrix} -4 \\ -2 \end{bmatrix} = -2 \begin{bmatrix} 2 \\ 1 \end{bmatrix}$ 有人耍廢

- $\text{Span}\left\{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}\right\} = \text{Span}\left\{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}\right\}$

➤ 觀察： $\begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix} = -4 \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + 1 \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$



「多餘向量」與線性組合

Span • 定義： $\text{Span}\{v_1, v_2, \dots, v_n\} = \{v_1, v_2, \dots, v_n \text{ 的所有線性組合}\}$
 $= \{\text{所有可能的 } c_1 \cdot v_1 + c_2 \cdot v_2 + \dots + c_n \cdot v_n\}$


• 定理：

$$\text{Span}\{v_1, v_2, \dots, v_n, \mathbf{w}\} = \text{Span}\{v_1, v_2, \dots, v_n\}$$

($\mathbf{w}$ 在耍廢)

↓ ↑

$\mathbf{w}$ 是 $v_1, v_2, \dots, v_n$ 的線性組合



Section 1.

向量

1. 向量與空間
2. 線性組合與 Span
3. 子空間
4. 線性獨立與基底

子空間

子空間

(subspace)

- 定義：向量空間 V 的子集合 S 被稱為 **子空間**，如果：

- S 包含 $\vec{0}$
- 對於任何 $v, w \in S$ ，都有 $v + c \cdot w \in S$

(所有線性組合都不離開 S)

(S 自己形成一個向量空間)


自給自足的小宇宙

例： $\mathbb{R}^3$ 中的二維平面 $\Rightarrow \mathbb{R}^3$ 的子空間

「結構」與 $\mathbb{R}^2$ 相同，但 不等於 $\mathbb{R}^2$

$$\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} 1 \\ 0 \end{bmatrix}$$



子空間 - 幾何範例

子空間


(subspace)

- 定義：向量空間 $\mathcal{V}$ 的子集合 $\mathcal{S}$ 被稱為 **子空間**，如果：

- $\mathcal{S}$ 包含 $\vec{0}$

- 對於任何 $v, w \in \mathcal{S}$ ，都有 $v + c \cdot w \in \mathcal{S}$ （所有線性組合都不離開 $\mathcal{S}$ ）

$$\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \quad \times$$




直線 $x = y = z$




$$= \left\{ \begin{bmatrix} x \\ y \\ z \end{bmatrix} \in \mathbb{R}^3 \mid x = y = z \right\} = \text{Span} \left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\}$$

$$\left\{ \begin{bmatrix} x \\ y \end{bmatrix} \in \mathbb{R}^2 \mid x, y \geq 0 \right\} \quad \times$$



$$\left\{ \begin{bmatrix} x \\ y \end{bmatrix} \in \mathbb{R}^2 \mid x^2 = y^2 \right\} \quad \times$$



資料維度與子空間


- 為何需要子空間：原始資料的維度災難



解析度 $224 * 224$:

$224 * 224$ 個方格、各填入 $0 \sim 255$

$$\in \mathbb{R}^{224} \times \mathbb{R}^{224} = \mathbb{R}^{224*224} = \mathbb{R}^{50176}$$



- 真實世界的影像在像素空間中**極度稀疏**
 - 機器學習：把原始資料投影到低維子空間，使資料變得**密集、有結構**
- $\mathbb{R}^{50176}$

壓縮、去雜訊

$\mathbb{R}^{512}$
- | | |
|---|--|
| <ul style="list-style-type: none">高維原始空間資料零散座標：像素位置 | <ul style="list-style-type: none">低維子空間資料密集緊湊座標：特徵
(毛茸茸程度、耳朵尖銳度) |
|---|--|

子空間特性

- 子空間與 Span

- $\text{Span}\{\text{任何向量}\} \Rightarrow \text{子空間}$

(Span : 所有可能線性組合)

(子空間 : 包含 $\vec{0}$ 、線性組合不離開子空間)

- 任何子空間 = $\text{Span}\{\text{某些向量}\}$?


(原始基底不適合用來描述子空間)

若 $\mathcal{V} = \text{Span } \mathcal{S}$, 則 $\mathcal{S}$ 被稱為 $\mathcal{V}$ 的 **Spanning Set**

- 目標：精準描述子空間

- 子空間 = $\text{Span}\{\text{某些向量}\}$

- 這些向量沒有人耍廢



Section 1.

向量

1. 向量與空間
2. 線性組合與 Span
3. 子空間
4. 線性獨立與基底

線性獨立與線性相依

線性相依

(Linearly dependent)

- 定義：向量集合 $\mathcal{S} = \{v_1, v_2, \dots, v_n\}$ 被稱為 **線性相依**，如果：
當中存在某向量 v_i 是其他向量的線性組合

$$\Leftrightarrow \text{Span}\{v_1, \dots, v_i, \dots, v_n\} = \text{Span}\{v_1, \dots, \cancel{v_i}, \dots, v_n\}$$

$$\Leftrightarrow \{v_1, \dots, v_i, \dots, v_n\} \text{ 裡面有人耍廢、沒貢獻} \\ \text{(依賴於別人)}$$

註：
若 $\mathcal{S}$ 包含 $\vec{0}$ ，
則 $\mathcal{S}$ 為線性相依

線性獨立

(Linearly independent)

- 定義：向量集合 $\mathcal{S} = \{v_1, v_2, \dots, v_n\}$ 被稱為 **線性獨立**，如果：
 $\mathcal{S}$ 不是線性相依

$$\Leftrightarrow \text{若 } c_1v_1 + c_2v_2 + \dots + c_nv_n = \vec{0}, \text{ 則 } c_1, \dots, c_n \text{ 必定全為 } 0$$

$$\Leftrightarrow \text{人人都有貢獻：拿掉任何一個向量，都會使 Span 變小}$$

基底

基底

(Basis)

- 定義：向量集合 $\beta = \{v_1, v_2, \dots, v_n\}$ 被稱為空間 $\mathcal{V}$ 的 **基底**，如果：

1. $\text{Span } \beta = \mathcal{V}$

完整覆蓋 $\mathcal{V}$ 、沒有遺漏資訊

2. β 是線性獨立

$\Leftrightarrow$

沒有人耍廢

- 例： $\left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$ 是 $\mathbb{R}^2$ 的一組基底

✓ $\left\{ \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}, \left\{ \begin{bmatrix} 3 \\ 2 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}, \left\{ \begin{bmatrix} -4 \\ 3 \end{bmatrix}, \begin{bmatrix} 1.4 \\ -2.8 \end{bmatrix} \right\}$

✗ $\left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}, \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ 2 \end{bmatrix} \right\}, \left\{ \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} -4 \\ 3 \end{bmatrix} \right\}$

- $\left\{ \begin{bmatrix} x \\ y \\ z \end{bmatrix} \in \mathbb{R}^3 \mid y = z \right\}$ 是 $\mathbb{R}^3$ 的子空間

$\left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\}, \left\{ \begin{bmatrix} -4 \\ 3 \\ 3 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} \right\}$

Span ?

線性獨立




- $\left\{ \begin{bmatrix} x \\ y \\ z \end{bmatrix} \in \mathbb{R}^3 \mid x - y + 2z = 0 \right\}$ 是 $\mathbb{R}^3$ 的子空間

$\left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -2 \\ 4 \\ 3 \end{bmatrix} \right\}$

Span ?

線性獨立



基底 - 毫無冗餘、完整覆蓋

基底

- 定義：向量集合 $\beta = \{v_1, v_2, \dots, v_n\}$ 被稱為空間 $\mathcal{V}$ 的 **基底**，如果：

(Basis)

1. $\text{Span } \beta = \mathcal{V}$

完整覆蓋 $\mathcal{V}$ 、沒有遺漏資訊

撐住全場

2. β 是線性獨立

$\Leftrightarrow$

沒有人耍廢

$\Leftrightarrow$

精銳部隊

- Exchange Lemma：若 $\mathcal{U}$ 、 $\mathcal{W}$ 是 $\mathcal{V}$ 的子集合，且 $\mathcal{U}$ 是線性獨立、 $\mathcal{W}$ 可以 span 出 $\mathcal{V}$ ，則：

$\mathcal{U}$ 的大小 $\leq \mathcal{W}$ 的大小（元素個數，記為 $|\mathcal{W}|$ ）

- Proof:

設 $\mathcal{U} = \{u_1, u_2, \dots, u_m\}$ 、 $\mathcal{W} = \{w_1, w_2, \dots, w_n\}$ ，欲證 $m \leq n$

因為 $\text{Span } \mathcal{W} = \mathcal{V}$ ，所以 $u_1 = c_1 \cdot w_1 + c_2 \cdot w_2 + \dots + c_n \cdot w_n$ ，係數不全為零

不失一般性，可假設 $c_1 \neq 0$ ，則 $w_1 = \frac{u_1 - (c_2 \cdot w_2 + \dots + c_n \cdot w_n)}{c_1}$

所以 $\mathcal{V} = \text{Span } \mathcal{W} = \text{Span}\{\cancel{w_1}, w_2, \dots, w_n\}$
 u_1

若換到第 i 次就提前結束，代表 $u_m \in \text{Span}\{u_1, u_2, \dots, u_i\}$ ，矛盾

新團隊：精銳部隊

舊團隊：撐住全場

一個精銳加入舊團隊

$\Rightarrow$ 有人互相依賴

$\Rightarrow$ 踢掉依賴的舊成員

基底與維度

基底

(Basis)

- 定義：向量集合 $\beta = \{v_1, v_2, \dots, v_n\}$ 被稱為空間 $\mathcal{V}$ 的 **基底**，如果：

1. $\text{Span } \beta = \mathcal{V}$

完整覆蓋 $\mathcal{V}$ 、沒有遺漏資訊

撐住全場

2. β 是線性獨立

$\Leftrightarrow$

沒有人耍廢

$\Leftrightarrow$

精銳部隊

- Exchange Lemma：若 $\mathcal{U}$ 、 $\mathcal{W}$ 是 $\mathcal{V}$ 的子集合，且 $\mathcal{U}$ 是線性獨立、 $\mathcal{W}$ 可以 span 出 $\mathcal{V}$ ，則：

$\mathcal{U}$ 的大小 $\leq \mathcal{W}$ 的大小（元素個數，記為 $|\mathcal{W}|$ ）

定義：若 β 是 $\mathcal{V}$ 的基底，
則 $|\beta|$ 被稱為 $\mathcal{V}$ 的 **維度**

- 定理：

1. 基底是最小的 Spanning Set

β ：基底 $\Rightarrow \beta$ 線性獨立

假設 $\text{Span } \mathcal{W} = \mathcal{V}$

根據 Lemma， $|\beta| \leq |\mathcal{W}|$

2. 基底是最大的線性獨立 Set

β ：基底 $\Rightarrow \text{Span } \beta = \mathcal{V}$

假設 $\mathcal{U}$ ：線性獨立

根據 Lemma， $|\mathcal{U}| \leq |\beta|$

3. 同一空間的不同基底的大小必相同

β, γ ：基底

$\Rightarrow \text{Span } \gamma = \mathcal{V}$

$\Rightarrow |\beta| \leq |\gamma|$

$\Rightarrow \gamma$ 線性獨立

$\Rightarrow |\gamma| \leq |\beta|$


基底判斷技巧

基底 (Basis)

- 定義：向量集合 $\beta = \{v_1, v_2, \dots, v_n\}$ 被稱為空間 $\mathcal{V}$ 的 **基底**，如果：

1. $\text{Span } \beta = \mathcal{V}$ 完整覆蓋 $\mathcal{V}$ 、沒有遺漏資訊
2. β 是線性獨立 $\iff$ 沒有人耍廢

- $\left\{ \begin{bmatrix} x \\ y \\ z \end{bmatrix} \in \mathbb{R}^3 \mid y = z \right\}$ 是 $\mathbb{R}^3$ 的子空間



$$\left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \right\} \quad \begin{array}{l} \text{Span} \quad \checkmark \\ \text{線性獨立} \quad \checkmark \end{array} \Rightarrow \text{基底} \Rightarrow \text{子空間維度} = 2$$

$$\left\{ \begin{bmatrix} -4 \\ 3 \\ 3 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} \right\} \quad \begin{array}{l} \text{Span} \quad ? \\ \text{線性獨立} \quad \checkmark \end{array} \Rightarrow \text{基底}$$

- $\left\{ \begin{bmatrix} x \\ y \\ z \end{bmatrix} \in \mathbb{R}^3 \mid x - y + 2z = 0 \right\}$ 是 $\mathbb{R}^3$ 的子空間

$\Rightarrow$ 3 個變數 1 個限制條件 $\Rightarrow$ 維度 = 2

$$\left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -2 \\ 4 \\ 3 \end{bmatrix} \right\} \quad \begin{array}{l} \text{Span} \quad ? \\ \text{線性獨立} \quad \checkmark \end{array} \Rightarrow \text{基底}$$

基底與唯一表示

基底

(Basis)

- 定義：向量集合 $\beta = \{v_1, v_2, \dots, v_n\}$ 被稱為空間 $\mathcal{V}$ 的 **基底**，如果：

1. $\text{Span } \beta = \mathcal{V}$ 完整覆蓋 $\mathcal{V}$ 、沒有遺漏資訊
2. β 是線性獨立 $\iff$ 沒有人耍廢

- 定理：若 β 是 $\mathcal{V}$ 的基底，則任意向量 $v \in \mathcal{V}$ 都可寫成 β 的線性組合，且**表示法唯一**

例： $v = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \in \mathbb{R}^2$

- $\beta = \left\{ \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 2 \end{bmatrix} \right\}$ ，則 $v = 1.5 \cdot \begin{bmatrix} 2 \\ 0 \end{bmatrix} + 1 \cdot \begin{bmatrix} 0 \\ 2 \end{bmatrix}$
- $\beta = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ 3 \end{bmatrix} \right\}$ ，則 $v = 5 \cdot \begin{bmatrix} 1 \\ 1 \end{bmatrix} + (-1) \cdot \begin{bmatrix} 2 \\ 3 \end{bmatrix}$
- $\beta = \left\{ \begin{bmatrix} 3 \\ 2 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$ ，則 $v = 1 \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix} + 0 \cdot \begin{bmatrix} 0 \\ 1 \end{bmatrix}$

證：設 $\beta = \{v_1, \dots, v_n\}$ ，且

$$v = a_1 \cdot v_1 + \dots + a_n \cdot v_n$$

$$v = b_1 \cdot v_1 + \dots + b_n \cdot v_n$$

$$\Rightarrow 0 = (a_1 - b_1) \cdot v_1 + \dots + (a_n - b_n) \cdot v_n$$


若有 $a_i - b_i \neq 0$ ，則 v_i 是其他 v_j 們的線性組合

因為 β 線性獨立，所以所有 $a_i - b_i = 0$

座標系統 (Pro)


- 定理：若 β 是 $\mathcal{V}$ 的基底，則任意向量 $v \in \mathcal{V}$ 都可寫成 β 的線性組合，且表示法唯一
- 任何基底都形成一個坐標系統（把線性組合的係數寫成「行向量」）
- 坐標系依賴於「基底」的選擇

例： $v = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$ $\beta = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$



● $\gamma = \left\{ \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 2 \end{bmatrix} \right\}$ $[v]_\gamma = \begin{bmatrix} 1.5 \\ 1 \end{bmatrix}$

● $\gamma = \left\{ \begin{bmatrix} 3 \\ 0 \end{bmatrix}, \begin{bmatrix} 3 \\ 2 \end{bmatrix} \right\}$ ，則 $v = 0 \cdot \begin{bmatrix} 3 \\ 0 \end{bmatrix} + 1 \cdot \begin{bmatrix} 3 \\ 2 \end{bmatrix}$





$$\beta : \begin{bmatrix} 3 \\ 2 \end{bmatrix} + \begin{bmatrix} 3 \\ -4 \end{bmatrix} = \begin{bmatrix} 6 \\ -2 \end{bmatrix}$$

$$\gamma : \begin{bmatrix} 0 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ -2 \end{bmatrix} = \begin{bmatrix} 3 \\ -1 \end{bmatrix}$$

回顧 - 向量、基底、座標

- 向量：有方向的量
 - 加法：平行四邊形法
 - 純量乘法：倍率縮放
- 基底：固定一組向量當基準，把所有向量寫成該基準的組合
- 座標系統：只記錄向量寫成基底組合時的係數
 - 座標系統依賴於基底的選擇
 - 默認選擇標準基底 $\{e_1, e_2\}$
- 可考慮高維度向量 $v \in \mathbb{R}^n$ $v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$



Section 2.

內積

1. 代數內積與幾何內積
2. 投影與座標系統
3. 相似度指標比較與應用
4. 基底變換與深度學習

代數內積 - 分量相乘

內積

(Inner Product)

- 向量 $\mathbf{v} = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$ 、 $\mathbf{w} = \begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix}$ 的內積定義為：

$$\mathbf{v} \cdot \mathbf{w} = v_1 \cdot w_1 + v_2 \cdot w_2 + \cdots + v_n \cdot w_n \in \mathbb{R}$$

(分量相乘後相加)

- 例：

$$\begin{bmatrix} 3 \\ 2 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ -4 \end{bmatrix} = 3 \cdot 3 + 2 \cdot (-4) = 1$$

$$\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \cdot \begin{bmatrix} -2 \\ 4 \\ 3 \end{bmatrix} = -2 + 4 + 0 = 2$$

- 性質：

交換律

$$\mathbf{v} \cdot \mathbf{w} = \mathbf{w} \cdot \mathbf{v}$$

加法可拆

$$(\mathbf{u} + \mathbf{v}) \cdot \mathbf{w} = \mathbf{u} \cdot \mathbf{w} + \mathbf{v} \cdot \mathbf{w}$$

係數可提

$$(c\mathbf{v}) \cdot \mathbf{w} = c(\mathbf{v} \cdot \mathbf{w})$$

與線性組合相容

直觀與運算的橋樑 - 線性組合

數學概念	幾何直觀	運算操作
● 向量	● 空間中的箭頭	● Column vector <code>np.array</code>
● 內積	● 投影	● 分量相乘後相加 <code>np.dot(v, w)</code>
● 線性函數	● 縮放、旋轉、剪切 ● 基底變換	● 矩陣乘向量 <code>A@v</code>
● 函數合成	● 連續空間變換	● 矩陣相乘 <code>A@B</code>

← 基底的線性組合 →

向量長度 (Norm) - 高維空間中的畢氏定理

範數 (長度)

(norm) • 向量 $\mathbf{v} = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$ 的 norm 定義為：


(2-norm)

$$\|\mathbf{v}\| = \sqrt{\mathbf{v} \cdot \mathbf{v}} = \sqrt{v_1^2 + v_2^2 \dots + v_n^2}$$

• 例：

$$\left\| \begin{bmatrix} -2 \\ 4 \\ 3 \end{bmatrix} \right\| = \sqrt{(-2)^2 + 4^2 + 3^2} = \sqrt{29}$$

高維版本畢氏定理



• 性質：

非負性	$\ \mathbf{v}\ \geq 0$
正定性	$\ \mathbf{v}\ = 0 \Leftrightarrow \mathbf{v} = \vec{0}$
係數可提	$\ c\mathbf{v}\ = c \ \mathbf{v}\ $


餘弦定理之幾何證明

餘弦定理

(law of cosines)


$$c^2 = a^2 + b^2 - 2ab \cos C$$

(純幾何，只用到畢氏定理)



● 證明：


$$\begin{aligned} c^2 &= (b \sin C)^2 + (a - b \cos C)^2 \\ &= b^2 \sin^2 C + a^2 - 2ab \cos C + b^2 \cos^2 C \\ &= b^2 (\sin^2 C + \cos^2 C) + a^2 - 2ab \cos C \\ &= a^2 + b^2 - 2ab \cos C \end{aligned}$$




幾何內積 - 與代數內積的統一

幾何內積

- $\mathbf{v} \cdot \mathbf{w} = \|\mathbf{v}\| \|\mathbf{w}\| \cos \theta$



餘弦定理： $c^2 = a^2 + b^2 - 2ab \cos C$



- 證明： 設 $\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$ 、 $\mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$ ，則 $\mathbf{v} - \mathbf{w} = \begin{bmatrix} v_1 - w_1 \\ v_2 - w_2 \end{bmatrix}$

$$\begin{aligned} \|\mathbf{v} - \mathbf{w}\|^2 &= (\mathbf{v} - \mathbf{w}) \cdot (\mathbf{v} - \mathbf{w}) = (v_1 - w_1)^2 + (v_2 - w_2)^2 \\ &= (v_1^2 + v_2^2) + (w_1^2 + w_2^2) - 2(v_1 w_1 + v_2 w_2) \\ &= \cancel{\|\mathbf{v}\|^2} + \cancel{\|\mathbf{w}\|^2} - 2 \mathbf{v} \cdot \mathbf{w} \end{aligned}$$

(把 $\|\mathbf{v} - \mathbf{w}\|^2$ 分別用定義、餘弦定理寫開、化簡)




$$\begin{aligned} \|\mathbf{v} - \mathbf{w}\|^2 &= \cancel{\|\mathbf{v}\|^2} + \cancel{\|\mathbf{w}\|^2} - 2 \|\mathbf{v}\| \|\mathbf{w}\| \cos \theta \end{aligned}$$

內積的幾何意義 - 投影長度


幾何內積

● $v \cdot w = \|v\| \|w\| \cos \theta$ (長長 $\cos$ 夾角)

(影長 $\times$ 底長)



$\cos \theta$




θ	$\cos \theta$	語意 / 特徵的 相似度 / 相關性
0°	1	高
60°	$\frac{1}{2}$	低
90°	0	無
120°	$-\frac{1}{2}$	相反
180°	-1	

正交基底與座標



幾何內積

- $v \cdot w = \|v\| \|w\| \cos \theta$ (長長 $\cos$ 夾角)
- (影長 $\times$ 底長)



向量投影

- $\|w\| \cos \theta = \frac{v \cdot w}{\|v\|}$



- 若基底正交



$$\text{向量座標} = \frac{\text{向量} \cdot \text{基底}}{\text{基底長度}}$$

非正交基底 - 平行四邊形法則



幾何內積

- $\mathbf{v} \cdot \mathbf{w} = \|\mathbf{v}\| \|\mathbf{w}\| \cos \theta$ (長長 $\cos$ 夾角)
(影長 $\times$ 底長)

- $\|\mathbf{w}\| \cos \theta = \frac{\mathbf{v} \cdot \mathbf{w}}{\|\mathbf{v}\|}$




$$\text{座標} = \frac{\text{向量} \cdot \text{基底}}{\text{基底長度}}$$



座標怎麼求？
下一單元：矩陣

距離 - 相似度指標比較


距離 ● v 與 w 的距離 = $\|v - w\|$



● 範例：電影推薦系統


- 向量 U ：目標使用者；向量 A 、 B 、 C ：電影
- 維度：電影類型指數

指標	定義	幾何觀點
距離	$\ v - w\ $	絕對位置
餘弦相似度 (夾角)	$\cos \theta = \frac{v \cdot w}{\ v\ \ w\ }$	方向
內積	$\sum_i v_i \cdot w_i$	方向 + 強度




距離 - 機器學習應用


距離 ● v 與 w 的距離 = $\|v - w\|$



● KNN：根據鄰近資料的類別，將新資料分類



● K-means：將未分類的資料，分為 K 個群體




正交變換 - 特性與應用


基底變換：改變觀察資料的視角，使資料分布更理想

- 正交基底特性：

- 高效計算：座標 = 內積
- 保持幾何特性：不改變向量距離、內積




- 應用：PCA (主成分分析)



非正交變換 - 扭曲空間以改變內積

基底變換：改變觀察資料的視角，使資料分布更理想

- 非正交基底特性：改變向量內積




空間變換：轉動視角 vs. 移動向量

基底變換：改變觀察資料的視角，使資料分布更理想


➤ 被動變換：改變觀察視角

- 向量固定
 - 座標系統改變
- ➡ 向量座標改變
- ➡ 向量內積改變



➤ 主動變換：把向量移動

- 所有向量以相同方式改變
 - 座標系統固定
- ➡ 向量內積改變



空間變換：模型訓練 / 推論的本質


模型訓練

$$F(x) = y$$

輸入

模型

輸出




模型推論

$$F(x) = y$$

輸入

模型



輸出




	模型訓練	模型推論
對應觀點	被動變換：改變觀察視角	主動變換：把向量移動
資料	固定 (真實資料，作為模型認知基準)	變動 (不同資料被固定流程層層變換)
模型	變動 (使預測結果變得接近真實資料)	固定 (模型訓練完成後就凍結參數)
幾何直覺	變換視角：一堆向量固定在空間中，模型旋轉 / 縮放座標軸，換個角度來解釋這堆向量	揉捏向量：座標系不動，輸入的向量被拿進空間中進行旋轉、拉伸或投影

空間變換：模型訓練 / 推論的本質

	模型訓練 $F(x) = y$	模型推論 $F(x) = y$
對應觀點	被動變換：改變觀察視角	主動變換：把向量移動
資料	固定	變動
模型	變動	固定
幾何直覺	變換視角：一堆向量固定在空間中，模型旋轉 / 縮放座標軸，換個角度來解釋這堆向量	揉捏向量：座標系不動，輸入的向量被拿進空間中進行旋轉、拉伸或投影



總結 - 從內積到深度學習



Section 3.

矩陣

1. 矩陣基本性質
2. 矩陣 $\times$ 向量
3. 線性函數
4. 矩陣 $\times$ 矩陣

矩陣 - 數值容器

矩陣

(Matrix)

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

row

column

- A 有 m 個 row、 n 個 column
- A 的形狀 / 大小 / 維度是 $m \times n$
- $M_{m \times n} = \{ \text{所有形狀是 } m \times n \text{ 的矩陣} \}$
- $A_{ij} = A$ 的第 i 個 row、 j 個 column 的元素
= A 的第 (i, j) 個元素

$$\begin{bmatrix} 1 & 5 \\ 2 & 6 \\ 3 & 7 \\ 4 & 8 \end{bmatrix}$$

||

$$A \in M_{4 \times 2}$$

```
1 import numpy as np
2 A = np.array([
3     [1, 5],
4     [2, 6],
5     [3, 7],
6     [4, 8]
7 ])
8 print(f"A的大小: {A.shape}")
```

A的大小: (4, 2)

```
1 print(f"A的第(2, 1)個元素: {A[1, 0]}")
```

$$A_{21} = 2$$

A的第(2, 1)個元素: 2

矩陣加法

矩陣

(Matrix)

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

row

column

$$, \quad B = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{m1} & b_{m2} & \cdots & b_{mn} \end{bmatrix} \in M_{m \times n}$$

- $A + B = \begin{bmatrix} a_{11} + b_{11} & \cdots & a_{1n} + b_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} + b_{m1} & \cdots & a_{mn} + b_{mn} \end{bmatrix}$

(分量各自相加)

- 對於任意係數 $c \in \mathbb{R}$, $cA = \begin{bmatrix} c a_{11} & \cdots & c a_{1n} \\ \vdots & \ddots & \vdots \\ c a_{m1} & \cdots & c a_{mn} \end{bmatrix}$

(分量各自乘係數)

- 形狀相同的矩陣可做線性組合 $cA + B$

矩陣加法與運算效率

矩陣

(Matrix)

$$A = \begin{bmatrix} 0 & 3 \\ 1 & 4 \\ 2 & 5 \end{bmatrix}, \quad B = \begin{bmatrix} 10 & 20 \\ 30 & 40 \\ 50 & 60 \end{bmatrix}, \quad 2A + B = \begin{bmatrix} 2 \cdot 0 + 10 & 2 \cdot 3 + 20 \\ 2 \cdot 1 + 30 & 2 \cdot 4 + 40 \\ 2 \cdot 2 + 50 & 2 \cdot 5 + 60 \end{bmatrix} = \begin{bmatrix} 10 & 26 \\ 32 & 48 \\ 54 & 70 \end{bmatrix}$$

- 逐 entry：雙層迴圈跑遍 A_{ij} 、 B_{ij}

```
for i in range(rows):  
    for j in range(cols):  
        result[i, j] = A[i, j] + B[i, j]
```

- 逐 row：將 row 視為向量相加

```
for i in range(rows):  
    result[i] = A[i] + B[i]
```

- 矩陣相加

```
result = A + B
```

- 效率測試

- 10,000 個 1,536 維向量相加
- (測試環境：Colab)

方法	耗時 (秒)
逐 entry	10.743
逐 row	0.088
矩陣相加	0.047

矩陣加法性質

矩陣

(Matrix)

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

row

column

$$, \quad B = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{m1} & b_{m2} & \cdots & b_{mn} \end{bmatrix} \in M_{m \times n}$$

對於形狀相同的矩陣 A, B, C 、純量 (實數) s, t

- $A + B = B + A$
- $(A + B) + C = A + (B + C)$
- $st(A) = s(tA)$
- $s(A + B) = sA + sB$
- $(s + t)A = sA + tA$

特殊矩陣

矩陣

(Matrix)

- 方形矩陣的對角線 (diagonal)

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

```
2 A = np.array([[1, 2, 3],
3               [4, 5, 6],
4               [7, 8, 9]])
5 print(np.diag(A))
[1 5 9]
```

- 單位矩陣 (identity)

$$I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

```
I = np.identity(3)
I = np.eye(3)
```

- 對角矩陣 (diagonal matrix)

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 9 \end{bmatrix}$$

```
1 d = np.array([1, 5, 9])
2 A = np.diag(d)
3 print(A)
[[1 0 0]
 [0 5 0]
 [0 0 9]]
```

- 0 矩陣

$$O = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

```
O = np.zeros((3, 4))
```

矩陣的轉置

轉置

- 若 $A \in M_{m \times n}$ ，則 A 的轉置為 $A^T \in M_{n \times m}$ ，其中 $(A^T)_{ij} = A_{ji}$

(Transpose)

觀點 1：行列互換

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} \xrightarrow{\text{Transpose}} A^T = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & 2 & 3 & 1 & 4 \\ 4 & 5 & 6 & 2 & 5 \\ 7 & 8 & 9 & 3 & 6 \end{bmatrix} \xrightarrow{\text{Transpose}} B^T = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \\ 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

觀點 2：沿對角線翻轉

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} \xrightarrow{\text{Transpose}} A^T = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & 2 & 3 & 1 & 4 \\ 4 & 5 & 6 & 2 & 5 \\ 7 & 8 & 9 & 3 & 6 \end{bmatrix} \xrightarrow{\text{Transpose}} B^T = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \\ 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

矩陣的轉置

轉置

(Transpose)

- 若 $A \in M_{m \times n}$ ，則 A 的轉置為 $A^T \in M_{n \times m}$ ，其中 $(A^T)_{ij} = A_{ji}$

NumPy 運算

```
1 import numpy as np
2 A = np.array([[1, 2, 3],
3               [4, 5, 6]])
4 print(A.T)
```

```
[[1 4]
 [2 5]
 [3 6]]
```

對於形狀相同的矩陣 A, B 、純量（實數） s

- $(A^T)^T = A$
- $(A + B)^T = A^T + B^T$
- $(sA)^T = s(A^T)$

矩陣與向量乘法 - Row 觀點

- 矩陣與向量乘法定義

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \in M_{m \times n}, \quad v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \in \mathbb{R}^n, \quad Av = \begin{bmatrix} a_{11}v_1 + a_{12}v_2 + \cdots + a_{1n}v_n \\ a_{21}v_1 + a_{22}v_2 + \cdots + a_{2n}v_n \\ \vdots \\ a_{m1}v_1 + a_{m2}v_2 + \cdots + a_{mn}v_n \end{bmatrix} \in \mathbb{R}^m$$

- Row 觀點：Row 與向量內積

$$A = \begin{bmatrix} - & r_1 & - \\ - & r_2 & - \\ & \vdots & \\ - & r_m & - \end{bmatrix} \in M_{m \times n}, \quad \begin{bmatrix} | \\ | \\ v \\ | \\ | \end{bmatrix} \in \mathbb{R}^n, \quad Av = \begin{bmatrix} r_1^T \cdot v \\ r_2^T \cdot v \\ \vdots \\ r_m^T \cdot v \end{bmatrix} \in \mathbb{R}^m$$

v 在 r_1 這個特徵的強度
 v 對 r_1 這個模板的符合度

- 直觀理解：每個 row 代表一個過濾器 / 特徵模板，透過乘法計算相似度

矩陣與向量乘法 - Column 觀點

- 矩陣與向量乘法定義

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \in M_{m \times n}, \quad v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \in \mathbb{R}^n, \quad Av = \begin{bmatrix} a_{11}v_1 + a_{12}v_2 + \cdots + a_{1n}v_n \\ a_{21}v_1 + a_{22}v_2 + \cdots + a_{2n}v_n \\ \vdots \\ a_{m1}v_1 + a_{m2}v_2 + \cdots + a_{mn}v_n \end{bmatrix} \in \mathbb{R}^m$$

- Column 觀點：Column 依照輸入的分量做線性組合

$$A = \begin{bmatrix} | & | & \cdots & | \\ c_1 & c_2 & \cdots & c_n \\ | & | & \cdots & | \end{bmatrix} \in M_{m \times n}, \quad v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \in \mathbb{R}^n, \quad Av = \begin{bmatrix} | & | & \cdots & | \\ v_1c_1 + v_2c_2 + \cdots + v_nc_n & | & \cdots & | \\ | & | & \cdots & | \end{bmatrix} \in \mathbb{R}^m,$$

- 直觀理解：矩陣 column 是固定材料，向量 v 提供配方，揉合出新向量 Av

矩陣與向量乘法 - 代數性質

- 矩陣與向量乘法定義

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \in M_{m \times n}, \quad v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \in \mathbb{R}^n, \quad Av = \begin{bmatrix} a_{11}v_1 + a_{12}v_2 + \cdots + a_{1n}v_n \\ a_{21}v_1 + a_{22}v_2 + \cdots + a_{2n}v_n \\ \vdots \\ a_{m1}v_1 + a_{m2}v_2 + \cdots + a_{mn}v_n \end{bmatrix} \in \mathbb{R}^m$$

- 對於矩陣 $A, B \in M_{m \times n}$ 、向量 $v, w \in \mathbb{R}^n$ 、純量（實數） s, t

- 向量線性組合

- $A(v + w) = Av + Aw$
- $A(sv) = s(Av)$

- 矩陣線性組合

- $(A + B)v = Av + Bv$
- $(sA)v = s(Av)$

- 特殊矩陣

- $A\vec{0} = \vec{0} \in \mathbb{R}^m$
- $0v = \vec{0} \in \mathbb{R}^m$
- $I_n v = v$

線性函數 - 定義與範例

- 函數 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 被稱為 線性函數 (線性映射 / 線性變換 / Linear map / Linear transformation) , 若對於任意向量 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ 、純量 c , 皆滿足 :

- $f(\mathbf{v} + \mathbf{w}) = f(\mathbf{v}) + f(\mathbf{w})$
- $f(c\mathbf{v}) = cf(\mathbf{v})$

- 例 : $f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} 2a + b \\ a \end{bmatrix}$$

$$\begin{bmatrix} 1 \\ 0 \end{bmatrix} \mapsto \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$+ \quad +$$

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix} \mapsto \begin{bmatrix} 7 \\ 2 \end{bmatrix}$$

$$\parallel \quad \parallel$$

$$\begin{bmatrix} 3 \\ 3 \end{bmatrix} \mapsto \begin{bmatrix} 9 \\ 3 \end{bmatrix}$$

- $f: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} 2a + b \\ a \\ a - b \end{bmatrix}$$

$$\begin{bmatrix} 1 \\ 2 \end{bmatrix} \mapsto \begin{bmatrix} 4 \\ 1 \\ -1 \end{bmatrix}$$

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix} \mapsto \begin{bmatrix} 5 \\ 2 \\ 1 \end{bmatrix}$$

- $f: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ 

$$\begin{bmatrix} a \\ b \\ c \end{bmatrix} \mapsto \begin{bmatrix} b - 2c \\ 2b \end{bmatrix}$$

$$\begin{bmatrix} -4 \\ 3 \\ 0 \end{bmatrix} \mapsto \begin{bmatrix} 3 \\ 6 \end{bmatrix}$$

$$\begin{bmatrix} 8 \\ -6 \\ 0 \end{bmatrix} \mapsto \begin{bmatrix} -6 \\ -12 \end{bmatrix}$$

- $f: \mathbb{R}^4 \rightarrow \mathbb{R}^2$ 

$$\begin{bmatrix} a \\ b \\ c \\ d \end{bmatrix} \mapsto \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

- $f: \mathbb{R}^2 \rightarrow \mathbb{R}^4$ 

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

線性函數 - 反例

- 函數 $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 被稱為 線性函數，若：

- $f(\mathbf{v} + \mathbf{w}) = f(\mathbf{v}) + f(\mathbf{w})$
- $f(c\mathbf{v}) = cf(\mathbf{v})$

- $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ❌

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} 2a + b \\ a + 1 \end{bmatrix}$$

$$\begin{bmatrix} 1 \\ 0 \end{bmatrix} \mapsto \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

+

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix} \mapsto \begin{bmatrix} 7 \\ 3 \end{bmatrix}$$

≠

$$\begin{bmatrix} 3 \\ 3 \end{bmatrix} \mapsto \begin{bmatrix} 9 \\ 4 \end{bmatrix}$$

- $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ❌

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} a^2 \\ b \end{bmatrix}$$

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix} \mapsto \begin{bmatrix} 4 \\ 1 \end{bmatrix}$$

+

$$\begin{bmatrix} -2 \\ 1 \end{bmatrix} \mapsto \begin{bmatrix} 4 \\ 1 \end{bmatrix}$$

≠

$$\begin{bmatrix} 0 \\ 2 \end{bmatrix} \mapsto \begin{bmatrix} 0 \\ 2 \end{bmatrix}$$

- $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ❌

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} |a| \\ b \end{bmatrix}$$

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix} \mapsto \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

+

$$\begin{bmatrix} -2 \\ 1 \end{bmatrix} \mapsto \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

≠

$$\begin{bmatrix} 0 \\ 2 \end{bmatrix} \mapsto \begin{bmatrix} 0 \\ 2 \end{bmatrix}$$

- $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ❌

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} e^a \\ e^b \end{bmatrix}$$

- $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ❌

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} \max(a, 0) \\ b \end{bmatrix}$$

- $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ❌

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} a \% 2 \\ b \end{bmatrix}$$

線性函數與矩陣

- 函數 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 被稱為 線性函數，若：

- $f(\mathbf{v} + \mathbf{w}) = f(\mathbf{v}) + f(\mathbf{w})$
- $f(c\mathbf{v}) = cf(\mathbf{v})$

- 給定矩陣 $A \in M_{m \times n}$ ，定義 $f_A: \mathbb{R}^n \rightarrow \mathbb{R}^m$

$$\mathbf{v} \mapsto A\mathbf{v}$$


$$A = \begin{bmatrix} 2 & 1 \\ 1 & 0 \end{bmatrix} \quad f_A\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

對於矩陣 $A \in M_{m \times n}$ 、向量 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ 、純量（實數） s

- 向量線性組合
 - $A(\mathbf{v} + \mathbf{w}) = A\mathbf{v} + A\mathbf{w}$
 - $A(s\mathbf{v}) = s(A\mathbf{v})$

所有矩陣都有唯一對應的線性函數

$$\begin{aligned} f_A(\mathbf{v} + \mathbf{w}) &= A(\mathbf{v} + \mathbf{w}) & f_A(s\mathbf{v}) &= A(s\mathbf{v}) \\ &= A\mathbf{v} + A\mathbf{w} & &= s(A\mathbf{v}) \\ &= f_A(\mathbf{v}) + f_A(\mathbf{w}) & &= sf_A(\mathbf{v}) \end{aligned}$$




線性函數與空間

如何「刻劃」線性函數 f ?

$$f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$$

$$\begin{bmatrix} a \\ b \end{bmatrix} \mapsto \begin{bmatrix} 2a + b \\ a \end{bmatrix} \quad \begin{bmatrix} 2 \\ 3 \end{bmatrix} \mapsto \begin{bmatrix} 7 \\ 2 \end{bmatrix}$$

如何描述一群向量的變換？



模型的學習

= 找到適用於訓練資料的變換
(一群向量)

● 函數 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 被稱為 線性函數，若：


$$\bullet f(\mathbf{v} + \mathbf{w}) = f(\mathbf{v}) + f(\mathbf{w})$$

$$\bullet f(c\mathbf{v}) = cf(\mathbf{v})$$

如何系統性的描述線性變換？

回顧：如何系統性的描述向量？ **基底**

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix} = 2\mathbf{e}_1 + 3\mathbf{e}_2$$



$$\begin{aligned} f\left(\begin{bmatrix} 2 \\ 3 \end{bmatrix}\right) &= f(2\mathbf{e}_1 + 3\mathbf{e}_2) \\ &= 2f(\mathbf{e}_1) + 3f(\mathbf{e}_2) \end{aligned}$$

只要知道 f 對基底 $\{\mathbf{e}_1, \mathbf{e}_2\}$ 的作用，就了解 f 對整個空間的作用

線性函數與基底

只要知道 f 對基底的作用，就了解 f 對整個空間的作用

$$f: \mathbb{R}^3 \rightarrow \mathbb{R}^5$$

$$\begin{bmatrix} a \\ b \\ c \end{bmatrix} \mapsto \begin{bmatrix} -c \\ a + b + c \\ 0 \\ 2b \\ 2a - c \end{bmatrix}$$

$$\mathbb{R}^3 \text{ 的標準基底: } \left\{ \mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}$$

$$f\left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 2 \end{bmatrix}, \quad f\left(\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 2 \\ 0 \end{bmatrix}, \quad f\left(\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}\right) = \begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \\ -1 \end{bmatrix}$$

$$f\left(\begin{bmatrix} 3 \\ 6 \\ 9 \end{bmatrix}\right) = f\left(3 \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + 6 \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} + 9 \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}\right)$$

$$= 3 \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 2 \end{bmatrix} + 6 \begin{bmatrix} 0 \\ 1 \\ 0 \\ 2 \\ 0 \end{bmatrix} + 9 \begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \\ -1 \end{bmatrix}$$

矩陣乘法

$$\text{Column 觀點} = \begin{bmatrix} 0 & 0 & -1 \\ 1 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 2 & 0 \\ 2 & 0 & -1 \end{bmatrix} \begin{bmatrix} 3 \\ 6 \\ 9 \end{bmatrix}$$

線性函數 $\leftrightarrow$ 矩陣

只要知道 f 對基底的作用，就了解 f 對整個空間的作用

對於任意線性函數 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 、 $\mathbf{v} \in \mathbb{R}^n$ ，


$$f(\mathbf{v}) = \begin{bmatrix} | & | & & | \\ f(\mathbf{e}_1) & f(\mathbf{e}_2) & \cdots & f(\mathbf{e}_n) \\ | & | & & | \end{bmatrix} \begin{bmatrix} | \\ | \\ \mathbf{v} \\ | \end{bmatrix}$$

- 對於任意線性函數 f ，透過觀測 f 對基底的作用，可構建出唯一的對應矩陣

所有線性函數都有唯一對應的矩陣


$$\begin{array}{c} f: \mathbb{R}^n \rightarrow \mathbb{R}^m \\ \text{線性} \end{array} \longleftrightarrow A \in M_{m \times n}$$

線性函數與矩陣一一對應



常見線性函數 - 旋轉

$f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ，把向量逆時針旋轉 θ



$$f(v + w) \stackrel{?}{=} f(v) + f(w) \quad \checkmark$$

相加後旋轉 $\stackrel{?}{=}$ 旋轉後相加



$$f(cv) = cf(v) \quad \checkmark$$

$\Rightarrow f$ 是線性函數 $\Rightarrow f$ 可寫成矩陣

觀測 f 對基底的作用


$$f = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

旋轉矩陣



常見線性函數 - 鏡射

$f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ，把向量對著夾角為 θ 的軸做鏡射



$$f(v+w) \stackrel{?}{=} f(v) + f(w)$$




相加後鏡射 $\stackrel{?}{=}$ 鏡射後相加

$$f(cv) = cf(v)$$




$\Rightarrow f$ 是線性函數 $\Rightarrow f$ 可寫成矩陣

觀測 f 對基底的作用




$$f = \begin{bmatrix} \cos 2\theta & \sin 2\theta \\ \sin 2\theta & -\cos 2\theta \end{bmatrix}$$

鏡射矩陣



常見線性函數 - 剪切

$f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ ，把向量水平推移，移動量與高度成正比



$$f(v+w) \stackrel{?}{=} f(v) + f(w)$$




相加後推移 $\stackrel{?}{=}$ 推移後相加

$$f(cv) = cf(v)$$



$\Rightarrow f$ 是線性函數 $\Rightarrow f$ 可寫成矩陣


觀測 f 對基底的作用



$$f = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$$


剪切矩陣 (水平) (垂直)
(shear)

$$\begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix}$$



常見線性函數 - 投影

$f: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ ，把 3 維向量投影到 2 維平面





$$f(v+w) \stackrel{?}{=} f(v) + f(w) \quad \checkmark$$

相加後投影 $\stackrel{?}{=}$ 投影後相加

$$f(cv) = cf(v) \quad \checkmark$$


$\Rightarrow f$ 是線性函數 $\Rightarrow f$ 可寫成矩陣

觀測 f 對基底的作用



常見線性函數 - 嵌入

$f: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ ，把 2 維向量放到 3 維空間（嵌入，embed）




$$f(v+w) \stackrel{?}{=} f(v) + f(w) \quad \checkmark$$

相加後嵌入 $\stackrel{?}{=}$ 嵌入後相加


$$f(cv) = cf(v) \quad \checkmark$$

$\Rightarrow f$ 是線性函數 $\Rightarrow f$ 可寫成矩陣

觀測 f 對基底的作用



$$f = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$$



矩陣乘法 - 定義

- 矩陣乘法定義

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \in M_{m \times n}, \quad B = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{np} \end{bmatrix} \in M_{n \times p}$$

$$AB = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} + \cdots + a_{1n}b_{n1} & \cdots & a_{11}b_{1p} + a_{12}b_{2p} + \cdots + a_{1n}b_{np} \\ \vdots & \ddots & \vdots \\ a_{m1}b_{11} + a_{m2}b_{21} + \cdots + a_{mn}b_{n1} & \cdots & a_{m1}b_{1p} + a_{m2}b_{2p} + \cdots + a_{mn}b_{np} \end{bmatrix} \in M_{m \times p}$$

矩陣乘法 - 範例

- 矩陣乘法範例

$$\cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 5 & 7 \\ 6 & 8 \end{bmatrix} = \begin{bmatrix} 1 \cdot 5 + 3 \cdot 6 & 1 \cdot 7 + 3 \cdot 8 \\ 2 \cdot 5 + 4 \cdot 6 & 2 \cdot 7 + 4 \cdot 8 \end{bmatrix} \in M_{2 \times 2}$$

$$\cdot \begin{bmatrix} 1 & 3 \\ 2 & 4 \\ 9 & 0 \end{bmatrix} \begin{bmatrix} 5 & 7 \\ 6 & 8 \end{bmatrix} = \begin{bmatrix} 1 \cdot 5 + 3 \cdot 6 & 1 \cdot 7 + 3 \cdot 8 \\ 2 \cdot 5 + 4 \cdot 6 & 2 \cdot 7 + 4 \cdot 8 \\ 9 \cdot 5 + 0 \cdot 6 & 9 \cdot 5 + 0 \cdot 6 \end{bmatrix} \in M_{3 \times 2}$$

3×2 2×2

$$\cdot \begin{bmatrix} 5 & 7 \\ 6 & 8 \end{bmatrix} \begin{bmatrix} 1 & 3 \\ 2 & 4 \\ 9 & 0 \end{bmatrix} = \text{無定義}$$

$$\cdot \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 4 & 5 & 6 \end{bmatrix} = \begin{bmatrix} 4 & 5 & 6 \\ 8 & 10 & 12 \\ 12 & 15 & 18 \end{bmatrix}$$

3×1 1×3

$$\cdot \begin{bmatrix} 4 & 5 & 6 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = [32]$$

1×3 3×1

$AB \neq BA$

矩陣乘法 - 批次向量 (batch) 之 Row 觀點

- 資料容器觀點：矩陣 = Column vector 並排

- 回顧：矩陣 * 向量 (Row 觀點)

$$\begin{bmatrix} - & r_1 & - \\ - & r_2 & - \\ & \vdots & \\ - & r_m & - \end{bmatrix} \begin{bmatrix} | \\ v_1 \\ | \end{bmatrix} = \begin{bmatrix} r_1^T \cdot v_1 \\ r_2^T \cdot v_1 \\ \vdots \\ r_m^T \cdot v_1 \end{bmatrix}, \quad \begin{bmatrix} - & r_1 & - \\ - & r_2 & - \\ & \vdots & \\ - & r_m & - \end{bmatrix} \begin{bmatrix} | \\ v_2 \\ | \end{bmatrix} = \begin{bmatrix} r_1^T \cdot v_2 \\ r_2^T \cdot v_2 \\ \vdots \\ r_m^T \cdot v_2 \end{bmatrix}$$

- 概念：計算向量與每個模板的符合度

- 矩陣 * 矩陣：同時算多組「矩陣 * 向量」

$$\begin{bmatrix} - & r_1 & - \\ - & r_2 & - \\ & \vdots & \\ - & r_m & - \end{bmatrix} \begin{bmatrix} | & | & \cdots & | \\ v_1 & v_2 & \cdots & v_n \\ | & | & \cdots & | \end{bmatrix} = \begin{bmatrix} r_1^T \cdot v_1 & r_1^T \cdot v_2 & \cdots & r_1^T \cdot v_n \\ \vdots & \vdots & \cdots & \vdots \\ r_m^T \cdot v_1 & r_m^T \cdot v_2 & \cdots & r_m^T \cdot v_n \end{bmatrix}$$

- 應用：把多個輸入排成矩陣，讓模型平行處理

矩陣乘法 - 批次向量 (batch) 之 Column 觀點

- 資料容器觀點：矩陣 = Column vector 並排

- 回顧：矩陣 * 向量 (Column 觀點)

$$\begin{bmatrix} | & | & \cdots & | \\ c_1 & c_2 & \cdots & c_n \\ | & | & \cdots & | \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} | & | & \cdots & | \\ v_1 c_1 + v_2 c_2 + \cdots + v_n c_n & & & \\ | & | & \cdots & | \end{bmatrix}$$

- 概念：依照配方 v 來組合固定的材料 c_i

- 矩陣 * 矩陣：同時算多組「矩陣 * 向量」

$$\begin{bmatrix} | & \cdots & | \\ c_1 & \cdots & c_n \\ | & \cdots & | \end{bmatrix} \begin{bmatrix} | & \cdots & | \\ v_1 & \cdots & w_1 \\ | & \cdots & | \\ v_n & \cdots & w_n \end{bmatrix} = \begin{bmatrix} | & | & \cdots & | \\ v_1 c_1 + \cdots + v_n c_n & \cdots & w_1 c_1 + \cdots + w_n c_n \\ | & | & \cdots & | \end{bmatrix}$$

- 概念：同時計算多組不同配方 $v, \dots, w$

矩陣乘法 - 批次向量 (batch) 之函數觀點

- 資料容器觀點：矩陣 = Column vector 並排

$$A \begin{bmatrix} | & & | \\ v_1 & \cdots & v_n \\ | & & | \end{bmatrix} = \begin{bmatrix} | & & | \\ Av_1 & \cdots & Av_n \\ | & & | \end{bmatrix}$$

- 回顧：矩陣 * 向量 (函數觀點)

$$\begin{bmatrix} | & & | \\ f(e_1) & \cdots & f(e_n) \\ | & & | \end{bmatrix} \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} | \\ v_1 f(e_1) + \cdots + v_n f(e_n) \\ | \end{bmatrix} = \begin{bmatrix} | \\ f \left(\begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} \right) \\ | \end{bmatrix}$$

- 概念：觀察基底去向，依照原始係數做線性組合

- 矩陣 * 矩陣：同時算多組「矩陣 * 向量」

$$\begin{bmatrix} | & & | \\ f(e_1) & \cdots & f(e_n) \\ | & & | \end{bmatrix} \begin{bmatrix} v_1 & \cdots & w_1 \\ \vdots & & \vdots \\ v_n & & w_n \end{bmatrix} = \begin{bmatrix} | \\ f \left(\begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} \right) \\ | \end{bmatrix} \cdots \begin{bmatrix} | \\ f \left(\begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix} \right) \\ | \end{bmatrix}$$

- 概念：同時計算函數 f 對多個不同向量 $v, \dots, w$ 的作用

矩陣乘法 - 函數觀點

- 函數觀點：矩陣 = 線性函數



$$A \in M_{m \times n} \iff f_A : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

$$B \in M_{n \times p} \iff f_B : \mathbb{R}^p \rightarrow \mathbb{R}^n$$

- 矩陣相乘 = 函數合成

$$AB \in M_{m \times p} \iff f_{AB} : \mathbb{R}^p \rightarrow \mathbb{R}^m$$

$$f_A \circ f_B : \mathbb{R}^p \rightarrow \mathbb{R}^n \rightarrow \mathbb{R}^m$$



$$\begin{array}{ccccc}
 \boxed{A} & \boxed{B} & = & \boxed{A} & \begin{array}{c} | \\ f_B(e_1) \\ | \end{array} \cdots & = & \boxed{\begin{array}{c} | \\ Af_B(e_1) \\ | \end{array} \cdots} \\
 \boxed{AB} & = & \boxed{\begin{array}{c} | \\ f_A \circ f_B(e_1) \\ | \end{array} \cdots} & = & \boxed{\begin{array}{c} | \\ f_A \left(\begin{array}{c} | \\ f_B(e_1) \\ | \end{array} \right) \\ | \end{array} \cdots}
 \end{array}$$

總結 - 矩陣的四種觀點

資料容器：矩陣 = column vector 並排

- $A \in M_{m \times n}$: m 個 row、 n 個 column
- 加法、係數積：逐分量運算
- 轉置：行列互換
- 整批運算比逐 entry 迴圈快約 200 倍

Column 觀點：線性組合

- $Av = v_1c_1 + v_2c_2 + \dots + v_nc_n$
- column 是固定材料， v 是配方
- 依配方揉合出新向量 Av
- AB ：同時計算多組配方

矩陣

四種觀點

Row 觀點：Row 與向量內積

- Av 的第 i 個分量 $= r_i^T \cdot v$
- 每個 row 是一個特徵模板
- 內積 $= v$ 與模板的符合度
- AB ：多個向量同時比對所有模板

函數觀點：矩陣 = 線性函數

- 矩陣 $\leftrightarrow$ 線性函數，一一對應
- column = 基底的去向 $f(e_i)$
- 旋轉、鏡射、剪切、投影、嵌入
- $AB = f_A \circ f_B$ ：矩陣相乘 = 函數合成


Section 4.

語言模型運作


1. Embedding
2. Attention
3. FFN
4. LM Head
5. Sampling

語言模型運作 - 文字接龍與 Vocabulary

- 語言模型運作：文字接龍
(Next-token prediction)




- 輸入的文字 (→ 編號) → One-Hot Encoding



語言模型運作 - Embedding Layer


2. Token Embedding ← One-Hot Encoding



語言模型運作 - 文字相關性

3. Attention (上下文化, Contextualize)


3.1 計算相關性



語言模型運作 - 加權和

3. Attention (上下文化, Contextualize)


3.2 加權和 (weighted sum)



語言模型運作 - Naïve Attention

3. Attention

概念



運算

$$\tilde{Z} = Z \cdot \text{Softmax}(Z^T \cdot Z)$$

Diagram illustrating the calculation of the attention weights $\tilde{Z}$ from the input embeddings Z .

The input embeddings Z are calculated as:

$$Z = W_{\text{emb}} \cdot \begin{bmatrix} \text{One - Hot} \end{bmatrix}$$

The diagram shows the relationship between the input embeddings Z and the attention weights $\tilde{Z}$. The input embeddings Z are calculated as $Z = W_{\text{emb}} \cdot \begin{bmatrix} \text{One - Hot} \end{bmatrix}$. The attention weights $\tilde{Z}$ are calculated as $\tilde{Z} = Z \cdot \text{Softmax}(Z^T \cdot Z)$.

The diagram also shows the relationship between the input embeddings Z and the attention weights $\tilde{Z}$. The input embeddings Z are calculated as $Z = W_{\text{emb}} \cdot \begin{bmatrix} \text{One - Hot} \end{bmatrix}$. The attention weights $\tilde{Z}$ are calculated as $\tilde{Z} = Z \cdot \text{Softmax}(Z^T \cdot Z)$.

The diagram also shows the relationship between the input embeddings Z and the attention weights $\tilde{Z}$. The input embeddings Z are calculated as $Z = W_{\text{emb}} \cdot \begin{bmatrix} \text{One - Hot} \end{bmatrix}$. The attention weights $\tilde{Z}$ are calculated as $\tilde{Z} = Z \cdot \text{Softmax}(Z^T \cdot Z)$.

語言模型運作 - Attention

3. Attention

$$\tilde{Z} = Z \cdot \text{Softmax}(Z^T \cdot Z)$$

$$\tilde{Z} = V \cdot \text{Softmax}(K^T \cdot Q)$$

$$Z = W_{\text{emb}} \cdot \begin{bmatrix} \text{One} - \text{Hot} \end{bmatrix}$$

$$Q = W_q \cdot Z$$

$$K = W_k \cdot Z$$

$$V = W_v \cdot Z$$

$$W_q, W_k, W_v \in M_{4096 \times 4096}$$

- row 觀點：通過特徵模板 / 過濾器
- 某種線性變換

痛點

- 模型表達能力受限（搜索空間太小）：模型只可調整 W_{emb} ，其餘為固定算法

- 角色混亂（功能未分工）：

- 提問者（Query）：詢問「誰和我有關」
- 回應者（Key）：回應「我有哪些特徵」
- 提供者（Value）：提供「我的實際資訊」

- 影片搜尋

- 搜尋欄輸入的關鍵字
- 影片標題、tag、描述
- 影片內容

- 圖書館找書

- 想找的主題
- 書名 / 類別
- 書本內容

語言模型運作 - Attention Block

3. Attention


$$\tilde{Z} = V \cdot \text{Softmax}(K^T \cdot Q)$$

$$Q = W_q \cdot Z$$

$$K = W_k \cdot Z$$


$$V = W_v \cdot Z$$

$$Z = W_{\text{emb}} \cdot \begin{bmatrix} \text{One} - \text{Hot} \end{bmatrix}$$



語言模型運作 - FFN

4. Feedforward Network (FFN) = MLP = 全連接層




$$W_{down} \in M_{4,096 \times 16,384}$$

$$W_{up} \in M_{16,384 \times 4,096}$$

$$W_{down} \cdot W_{up} \in M_{4,096 \times 4,096}$$

等價於原始空間的某線性函數




非線性函數 ReLU

$$\begin{bmatrix} 0 \\ 2.7 \\ 0 \end{bmatrix} = \text{ReLU} \left(\begin{bmatrix} -4 \\ 2.7 \\ -0.1 \end{bmatrix} \right)$$

語言模型運作 - 矩陣運算

4. Feedforward Network (FFN) = MLP = 全連接層




運算

$$H = W_{down} \cdot \text{ReLU} \left(W_{up} \cdot \left(V \cdot \text{Softmax}(K^T \cdot Q) \right) \right)$$
$$\begin{aligned} Q &= W_q \cdot Z \\ K &= W_k \cdot Z \\ V &= W_v \cdot Z \end{aligned} \quad Z = W_{emb} \cdot \left[\text{One - Hot} \right]$$


語言模型運作 - 轉回 token

5. LM Head




語言模型運作 - Sampling


5. LM Head




- 選最高分者 (Greedy decoding)
- Top-k sampling



語言模型運作 - Causal Attention




- Bidirectional Attention




- 例：BERT

- Causal Attention (只往左看)



- 例：GPT

總結 - 語言模型中的線性代數




語言模型的骨架：查表、內積、加權和、線性函數；非線性只來自 **ReLU** 與 **Softmax**

Section 5.


補充

1. Rank
2. LoRA

函數的資訊量




$$\begin{bmatrix} 1 & 0.5 & 0 \\ 0 & 1 & 0.5 \\ 0.2 & 0 & 1 \end{bmatrix}$$




$$\begin{bmatrix} 1 & -1 & 0 \\ 1 & 1 & 2 \\ 0 & 1 & 1 \end{bmatrix}$$

資訊丟失



$$\begin{bmatrix} 1 & 2 & -1 \\ 1 & 2 & -1 \\ 1 & 2 & -1 \end{bmatrix}$$

資訊丟失



如何判斷函數是否丟失資訊、丟失多少？

Rank - 定義與範例

秩 (Rank) • 定義：Rank A = Dimension(Span{ A 的 column })
= 「 A 的 column 所 Span 出的空間」的維度
= 「線性獨立的 column 數」

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

row

column

$$\begin{bmatrix} 1 & 0.5 & 0 \\ 0 & 1 & 0.5 \\ 0.2 & 0 & 1 \end{bmatrix} \Rightarrow \left\{ \begin{bmatrix} 1 \\ 0 \\ 0.2 \end{bmatrix}, \begin{bmatrix} 0.5 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0.5 \\ 1 \end{bmatrix} \right\}$$

線性獨立

$\Rightarrow$ Rank = 3
(稱為 Full Rank)

$$\begin{bmatrix} 1 & -1 & 0 \\ 1 & 1 & 2 \\ 0 & 1 & 1 \end{bmatrix} \Rightarrow \left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 2 \\ 1 \end{bmatrix} \right\}$$

拿掉任一向量才線性獨立

$\Rightarrow$ Rank = 2

$$\begin{bmatrix} 1 & 2 & -1 \\ 1 & 2 & -1 \\ 1 & 2 & -1 \end{bmatrix} \Rightarrow \left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix}, \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix} \right\}$$


三向量平行

$\Rightarrow$ Rank = 1

Rank - 直觀意義

Rank • 定義：Rank $A = \text{Dimension}(\text{Span}\{A \text{ 的 column}\})$
= 「 A 的 column 所 Span 出的空間」的維度
= 「線性獨立的 column 數」

- 回顧：矩陣的 column = 基底的「去向」
- 若 A 是 3×3 矩陣，但 Rank = 2
⇒ 基底轉換後，變成線性相依（不獨立，有依賴關係）
⇒ 轉換後，能「撐起」的空間塌陷了 ⇒ 資訊壓縮
- 「壓縮」不一定是壞事
常刻意設計資訊瓶頸，強迫模型過濾雜訊，提取出重要特徵



$$A = \begin{bmatrix} 1 & -1 & 0 \\ 1 & 1 & 2 \\ 0 & 1 & 1 \end{bmatrix}$$
$$A \cdot e_1 = f_A(e_1)$$


低秩分解 (Low-Rank Factorization)

拆解虛胖的矩陣

- 定理：給定 $m \times n$ 的矩陣 W ，若 $\text{Rank}(W) = r$ ，則存在 $A \in M_{r \times n}$ 、 $B \in M_{m \times r}$ ，使得 $W = B \times A$
(虛胖的大矩陣，可以拆成兩個精實的小矩陣相乘)


- $$\begin{bmatrix} 1 & -1 & 0 \\ 1 & 1 & 2 \\ 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

Rank = 2 $M_{3 \times 2}$ $M_{2 \times 3}$



- $$\begin{bmatrix} 1 & 1 & 3 & 4 & 3 \\ 2 & 0 & 4 & 2 & 2 \\ 0 & 1 & 1 & 3 & 2 \\ 1 & 2 & 4 & 7 & 5 \\ 3 & 1 & 7 & 6 & 5 \\ 2 & 2 & 6 & 8 & 6 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 2 & 0 \\ 0 & 1 \\ 1 & 2 \\ 3 & 1 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 & 1 & 1 \\ 0 & 1 & 1 & 3 & 2 \end{bmatrix}$$

$M_{6 \times 5}$, Rank = 2 $M_{6 \times 2}$ $M_{2 \times 5}$




語言模型微調

- 情境：手上有大公司訓練好的通用大模型（開源語言模型），想讓它學會特定任務、特定風格

- 傳統做法：全參數微調（Full Fine-tuning）

$$W_{\text{new}} = W_{\text{old}} + \Delta W$$


- 痛點：
 - 很吃記憶體： ΔW 與 W_{old} 一樣大
以 BF16 精度為例，8B 模型的 W_{old} 、 ΔW 各需 16 GB VRAM
 - 自由度過大：容易過擬合（overfitting）
若模型腦容量較大，且訓練資料不多，模型可能硬背答案
- 洞見：若模型基礎夠好，且新任務不難，則不須調整所有維度



LoRA (Low-Rank Adaptation)

LoRA：訓練兩個小矩陣，組成虛胖的 ΔW

- 主要參數矩陣：



$\times 32$

- LoRA：

$$\left(W_q + \Delta W_q \right) * I$$

$4096 * 4096$

$$\Delta W_{up} = B * A$$

$16384 * 4096$ $16384 * r$ $r * 4096$

- 訓練參數量

訓練方法	全量微調	LoRA ($r = 16$)
訓練參數量	8 B	33 M (0.4%)

$$\left(\begin{matrix} (4096 * 16 * 2) * 3 \\ (16384 * 16 + 16 * 4096) * 2 \end{matrix} \right) * 32$$

LoRA 示範 code

```
from transformers import AutoModelForCausalLM
from peft import LoraConfig, get_peft_model

model = AutoModelForCausalLM.from_pretrained("meta-llama/Meta-Llama-3-8B")
lora_config = LoraConfig(
    r=16,
    lora_alpha=32,
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj"], 只對 Attention 微調
    lora_dropout=0.05,
    bias="none",
    task_type="CAUSAL_LM",
)

model = get_peft_model(model, lora_config)
model.print_trainable_parameters()
```

LoRA 示範 code - 進階

```
from transformers import AutoModelForCausalLM
from peft import LoraConfig, get_peft_model

model = AutoModelForCausalLM.from_pretrained("meta-llama/Meta-Llama-3-8B")
train_layers = list(range(8, 32)) 0~7 層不微調
rank_pattern = {f"model.layers.{i}": 16 for i in range(24, 32)} 24~32 層 rank=16
lora_config = LoraConfig(
    r=8, 8~23 層 rank=8
    lora_alpha=16,
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj", Attention
                    "gate_proj", "up_proj", "down_proj", ], FFN
    layers_to_transform=train_layers,
    rank_pattern=rank_pattern,
    lora_dropout=0.05,
    bias="none",
    task_type="CAUSAL_LM",
)
model = get_peft_model(model, lora_config)
model.print_trainable_parameters()
```

總結 - 線性代數

單元	核心觀念	直觀	AI 中的角色
1. 向量	向量、線性組合、Span 線性獨立、基底、座標	基底：撐住全場、沒人耍廢 座標：基底組合的係數	資料 = 高維向量 投影到低維子空間萃取特徵
2. 內積	內積、Norm、距離、投影 正交 / 非正交變換	內積 = 長長 $\cos$ 夾角 衡量相似度、相關性	KNN、K-Means、PCA 訓練、推論 = 兩種空間變換
3. 矩陣	矩陣 $\times$ 向量、矩陣 $\times$ 矩陣 線性函數	row 是模板、column 是材料 矩陣相乘 = 函數合成	多筆資料排成矩陣平行運算 模型層層做空間變換
4. 語言模型	Embedding、Attention、FFN LM Head、Sampling	查表、內積、加權和 升維 $\rightarrow$ ReLU $\rightarrow$ 降維	文字接龍 預測下一個 token
5. 補充	Rank、低秩分解 LoRA	Rank = 撐起的空間維度 虛胖矩陣拆成兩個小矩陣	LoRA 只訓練約 0.4% 參數 就能微調大模型

線性代數決定模型的架構：資料怎麼表示（向量）、怎麼比較（內積）、怎麼變換（矩陣）