

機器學習數學 測驗卷 — 答案與詳解

一、線性代數

第 1 題 答案：(C)

某房價資料集已有「臥室數」與「衛浴數」兩個欄位。工程師新增一欄「總房間數 = 臥室數 + 衛浴數」，再訓練線性模型：

$$\hat{y} = w_1 \cdot \text{臥室數} + w_2 \cdot \text{衛浴數} + w_3 \cdot \text{總房間數} + b$$

- (A) 多了一個特徵，模型能表達的預測範圍變大，因此有機會學到原本學不到的關係
- (B) 「總房間數」同時包含另外兩欄的資訊，所以它的權重 w_3 會是三者中最大的
- **(C) 任何用到「總房間數」的加權和，都能只用「臥室數」與「衛浴數」改寫，模型能表達的預測範圍和原本相同**
- (D) 若要移除冗餘欄位，只能刪除新增的「總房間數」；刪掉「臥室數」就會遺失資訊
- (E) 三個欄位彼此線性獨立，因為沒有任何一個欄位剛好是另一個欄位的倍數

核心觀念：線性相依的向量是「多餘向量」，加進來不會讓 Span 變大。

把每個欄位看成一個 column vector（每筆資料一個分量），線性模型的預測就是這幾個欄位的線性組合（加權和）。因為「總房間數」= 臥室數 + 衛浴數，它本身就是另外兩欄的線性組合。所以這個新欄位在「耍廢」：三個欄位線性相依，Span 出來的空間和原本兩欄完全一樣。

代入就能看出來：

$$w_1 \cdot \text{臥} + w_2 \cdot \text{衛} + w_3(\text{臥} + \text{衛}) = (w_1 + w_3) \cdot \text{臥} + (w_2 + w_3) \cdot \text{衛}$$

不管 w_3 是多少，結果都能只用兩個欄位寫出來。

選項解析

- (A) 錯。模型能表達的預測，就是這些欄位能 Span 出來的空間。新欄位是舊欄位的線性組合，Span 沒有變大，所以學不到新的關係。
- (B) 錯。從上面的式子可以看出，同一組預測可以用無限多組 (w_1, w_2, w_3) 寫出來，例如把 w_3 加 1、再把 w_1, w_2 各減 1，預測完全不變。基底不唯一時，係數（座標）就不唯一， w_3 的大小沒有意義，更不會「一定最大」。
- (C) 對。理由見上方核心觀念。
- (D) 錯。三個欄位中任何一個都能用另外兩個表示，例如臥室數 = 總房間數 - 衛浴數。刪掉任何一個都不會遺失資訊，剩下的兩個都能組成一組基底。
- (E) 錯。線性獨立的定義不是「沒有誰是誰的倍數」，而是「沒有任何一個向量能寫成其他向量的線性組合」。倍數只是線性組合的特例。這裡總房間數 = $1 \cdot \text{臥} + 1 \cdot \text{衛}$ ，所以三者線性相依。

對應課程觀念：線性組合、Span、多餘向量、線性獨立與線性相依、基底、唯一表示

第 2 題 答案：(E)

使用者以「各類型電影觀看量」向量表示。甲看很多電影；乙看得少，但各類型比例和甲完全相同，乙的向量剛好是甲的一半。想找出「口味相近」、且不受看片量影響的使用者。

- (A) 歐氏距離 $\|v - w\|$ ：兩個向量的差距越小，代表口味越相近，最適用此情境
- (B) 內積 $v \cdot w$ ：內積可捕捉向量相似度，最適用此情境
- (C) 歐氏距離和內積只是算法不同，對「誰最相似」的排序結果會一致
- (D) 內積為 0 代表兩人口味完全相反，應該推薦與對方完全相反類型的電影
- **(E) 餘弦相似度：只看兩個向量的夾角，最適用此情境**

核心觀念：三種相似度指標的幾何意義不同。

指標	定義	幾何觀點
距離	$\ v - w\ $	絕對位置
內積	$v \cdot w = \ v\ \ w\ \cos \theta$	方向 + 強度
餘弦相似度	$\cos \theta = \frac{v \cdot w}{\ v\ \ w\ }$	只看方向

「口味」對應的是各類型的**比例**，也就是向量的方向；「看片量」對應的是向量的**長度**。題目要求不受看片量影響，就應該選只看方向的餘弦相似度。甲和乙方向相同，夾角為 0， $\cos \theta = 1$ ，正好判定為口味最相近。

選項解析

- (A) 錯。乙 = 甲的一半，所以 $\|\text{甲} - \text{乙}\| = \frac{1}{2}\|\text{甲}\|$ ，甲看得越多，兩人的距離就越大。距離受長度影響，口味完全相同的人反而可能被判為不相近。
- (B) 錯。內積等於「長 $\cos$ 夾角」，會被向量長度放大。看片量大的使用者跟誰的內積都偏大，不符合「不受看片量影響」。
- (C) 錯。三種指標的幾何意義不同，排序結果可能不一樣。課堂的電影推薦例子中，三種指標各自選出不同的電影。
- (D) 錯。內積為 0 代表 $\cos \theta = 0$ ，也就是兩向量垂直，意義是「無相關」；「相反」是 $\cos \theta = -1$ 。
- (E) 對。

對應課程觀念：距離、餘弦、內積作為相似度指標的比較

第 3 題 答案：(E)

FFN 先用 W_{up} 把 4,096 維升到 16,384 維，經過 ReLU，再用 W_{down} 降回 4,096 維。如果把中間的 ReLU 拿掉，會發生什麼事？

- (A) ReLU 可把升維後的向量數值控制在一定數量級，拿掉後訓練容易發散
- (B) 無法計算，因為兩個矩陣的維度不相容，不能直接相乘

- (C) ReLU 可隔絕 token 之間的關聯性，拿掉後 FFN 會類似一個 Attention 層，計算 token 之間的相關性
- (D) 模型計算量倍增，影響訓練和推論速度
- **(E) 若忽略 Bias，整個 FFN 等價於原始空間中的一個線性函數，模型表達能力變低**

核心觀念：矩陣相乘就是函數合成，兩個線性函數合成後仍然是線性函數。加入 ReLU 就是為了引入非線性
拿掉 ReLU 後，FFN 變成

$$W_{\text{down}} \cdot (W_{\text{up}} \cdot z) = (W_{\text{down}} \cdot W_{\text{up}}) \cdot z$$

其中 $W_{\text{down}} \cdot W_{\text{up}}$ 是一個 $4,096 \times 4,096$ 的矩陣。也就是說，升維再降維的效果，等同於在原本的 4,096 維空間中做一個線性函數，升到 16,384 維就失去意義。

課堂的總結是：語言模型的骨架是查表、內積、加權和、線性函數，**非線性只來自 ReLU 與 Softmax**。少了非線性，再多層也只能疊成一個線性函數，能表達的函數就受限了。

選項解析

- (A) 錯。ReLU 是 $\max(0, x)$ ，只把負值變成 0，正值原樣保留，沒有上限，不負責控制數值大小。它在 FFN 中的作用是提供非線性。
- (B) 錯。 W_{down} 是 $4,096 \times 16,384$ ， W_{up} 是 $16,384 \times 4,096$ ，中間的維度都是 16,384，可以相乘。
- (C) 錯。FFN 本來就是對每個 token 各自運算，不論是否拿掉 ReLU。計算 token 之間相關性的是 Attention（內積 $\rightarrow$ Softmax $\rightarrow$ 加權和）。
- (D) 錯。ReLU 不是用於減少計算量，拿掉它不會讓計算量倍增。真正的問題在表達能力，不在速度。
- (E) 對。題目寫「忽略 Bias」，是因為實際模型通常是「線性函數 + 常數向量」，上課為了簡化只提線性函數，省略用於平移的常數向量。

對應課程觀念：矩陣乘法 = 函數合成、FFN、ReLU

第 4 題 答案：(D)（本題選錯誤的敘述）

採用 causal attention，每個中文字是一個 token。輸入「我喜歡海邊」與「我喜歡海鮮」，其中「海」字經 Embedding 後向量相同。下列何者**錯誤**？

- (A) Causal Attention 中，每個 token 作為 Query，只能與自己及其左側的 token 計算 Attention；但同一序列中各位置的 Attention 仍可平行計算
- (B) Attention 的核心概念是「計算 token 之間的相關性，再依此做加權和」
- (C) 若以矩陣左乘、column vector 的形式來看，「Q 和 K 內積算出相關性分數，經過 softmax 變成權重，再把 V 依照此權重做加權和」的流程可以寫成 $V \cdot \text{Softmax}(K^T \cdot Q)$
- **(D) 由於內積、加權和都可以寫成矩陣乘法，整個 Attention 層是線性的**
- (E) 因為 Causal Attention 只往左看，且 FFN 是每個 token 獨立運算，對題目的這兩個輸入而言，在每個對應的 Transformer layer 中，「海」這個位置的輸出向量都會相同

核心觀念：Attention = 內積（row 觀點） $\rightarrow$ Softmax 歸一化 $\rightarrow$ 加權和（column 觀點）。其中 Softmax 是非線性的。

選項解析

- (A) 正確。Causal Attention 只往左看，例如 GPT。但各位置的運算互不等待，可以把所有位置排成矩陣一次算完，只是把「右邊」的權重遮掉。這就是「把多個輸入排成矩陣，平行處理」。
- (B) 正確。Attention 的目的是「上下文文化」：先算相關性，再做加權和，讓向量依上下文改變。
- (C) 正確。 $K^T \cdot Q$ 用 row 觀點看，就是每個 Key 和每個 Query 做內積，得到相關性分數；Softmax 把分數歸一化成權重； $V \cdot (\text{權重})$ 用 column 觀點看，就是把 V 的 column 依權重做線性組合（加權和）。
- **(D) 錯誤，為本題答案。**內積和加權和確實是矩陣乘法，但中間的 **Softmax 是非線性函數**（含指數與除法），所以整個 Attention 層不是線性的。回顧課堂總結：「非線性只來自 ReLU 與 Softmax」。
- (E) 正確。兩句話的前四個字都是「我喜歡海」，差別只在第五個字（邊／鮮）。
 - 第 1 層：「海」的位置只能看「我、喜、歡、海」，這四個 token 的向量在兩個輸入中完全相同，所以 Attention 輸出相同；FFN 對每個 token 獨立運算，輸出也相同。
 - 第 2 層以後：「海」及其左側各位置的輸入，都是上一層的相同輸出，同樣的理由一層層延續，每一層「海」的輸出都相同。
 - 只有在第五個位置（邊／鮮），兩個輸入才開始不同。
 - 如果是 Bidirectional Attention（如 BERT），「海」會看到右邊的「邊」或「鮮」，輸出就會不同。

對應課程觀念：批次平行處理、Attention、Causal vs. Bidirectional Attention

二、微積分

第 5 題 答案：(E)

為什麼用梯度下降逐步調整參數，而不是直接求出 Loss 的最低點？

- (A) 梯度下降保證能找到 Loss 的全域最小值，直接求解只能找出局部最小值（local minimum）
- (B) 直接求解會讓模型過擬合（overfitting），梯度下降可以確保泛化性
- (C) 梯度下降一次只更新一個參數，比直接求解更省記憶體
- (D) 深度學習的 Loss 是二次函數，用梯度下降比較快找到極值點
- **(E) 深度學習模型的 Loss 通常是高維的複雜函數，沒有可直接求出全域最小值的通用方法**

核心觀念：寫不出、解不出，但算得出腳下的坡度。

類比情境：被空投到濃霧瀰漫的山上，目標是下山。

- **做不到：**看清整座山（寫出函數公式、畫出函數圖形）、直接找出最低點。
- **做得到：**感受腳下的坡度（計算目前位置的梯度）。

策略是朝最陡的下坡方向走一小步，重新感受坡度，再走一步，反覆進行。深度學習模型有數百萬甚至數十億個參數，Loss landscape 極度複雜，所以只能用這種方式。

選項解析

- (A) 錯。梯度下降的特性之一就是**無法確保終點是最低點**，可能停在局部低點。

- (B) 錯。過擬合跟「用什麼方法找參數」沒有直接關係，取決於模型容量、資料量等因素。梯度下降也不能確保泛化性。
- (C) 錯。梯度是所有偏微分組成的向量，梯度下降**同時**更新所有參數（不同參數代表不同維度）。
- (D) 錯。只有課堂入門的單變數例子（線性迴歸 + MSE，固定 b 只看 w ）是二次函數。深度學習的 Loss 是高維、多峰谷的複雜函數。
- (E) 對。

對應課程觀念： Loss Landscape、梯度下降策略與特性

第 6 題 答案：(A)

微調 8B 模型時 CUDA out of memory，同事建議開啟梯度檢查點（Gradient Checkpoint）。

- **(A) 前向傳播時不儲存所有 activations，要用再重算，減少 VRAM 用量，但訓練時間增加**
- (B) 更有效的釋放已經用完的 activations，即時釋出 VRAM，但會增加 VRAM 和 SRAM 間的讀寫
- (C) 減少模型被訓練的參數量，所以 VRAM 下降，但模型準確度會略為降低
- (D) 它使用較低的精度儲存 activations 和梯度，減少 VRAM 用量，但訓練會較不穩定
- (E) 它把梯度改存到 SSD，因此不再受 VRAM 容量限制，但讀寫會變慢

核心觀念：以時間換空間。

1. **為什麼 VRAM 會爆？** 反向傳播時，每一層要用「局部梯度」乘上上游梯度，而局部梯度需要用到前向傳播時該層的輸出（activations）。所以前向傳播時必須把每一層的 activations 存在 VRAM 裡，等反向傳播使用。模型越深、batch 越大、序列越長，activations 就越多。
2. **梯度檢查點怎麼做？** 前半段的 activations 算完就丟，只保留少數檢查點。反向傳播需要時，重新做一次前向傳播（不需要走到最後）。
3. **代價：**多做了重算，訓練時間增加。但算出的梯度和原本一模一樣，不影響訓練結果。

選項解析

- (A) 對。
- (B) 錯。activations 不是「用完」才被保留，而是反向傳播**還要用**才必須保留，所以無法提早釋放。梯度檢查點的代價是重算的時間，不是 VRAM 與 SRAM 之間的讀寫。
- (C) 錯。梯度檢查點不改變參數量，梯度也完全相同，不會降低準確度。「減少被訓練的參數量」比較像是 LoRA 的做法。
- (D) 錯。這描述的是降低數值精度的做法，不是梯度檢查點。
- (E) 錯。梯度檢查點跟 SSD 無關。

對應課程觀念： GPU 記憶體階層、activations 與 VRAM 壓力、梯度檢查點

第 7 題 答案：(E)

反向傳播中每層「接收上游梯度 → 乘上局部梯度 → 傳給下游」。若很深的網路中每層局部梯度大小約 0.5，靠近輸入端的前幾層會怎樣？

- (A) 每層的梯度各自獨立計算、互不影響，前幾層與後幾層的學習速度相同
- (B) 前幾層的梯度會變得非常大，導致參數更新過猛、訓練發散
- (C) 只會影響前向傳播的輸出數值，不會影響參數的更新
- (D) 因為近輸入端的梯度數值較小，模型會自動啟用高精度，使 VRAM 占用增加
- **(E) 梯度經過層層相乘後趨近於 0，前幾層的參數幾乎不會被更新**

核心觀念：連鎖律「串聯相乘」→ 梯度消失。

連鎖律告訴我們：**整體影響 = 局部影響相乘**。反向傳播從輸出往輸入走，每經過一層就乘上一次該層的局部梯度。若每層約 0.5，傳到第 n 層前時大約是

$$0.5^n, \quad \text{例如 } 0.5^{10} \approx 0.001, 0.5^{30} \approx 10^{-9}$$

梯度幾乎變成 0。參數更新量 = 學習率 × 梯度，所以前幾層的參數幾乎不動，等於學不到東西，這被稱為**梯度消失**。反過來，如果每層局部梯度都明顯大於 1，連乘後會急遽變大，就是**梯度爆炸**。之後深度學習課程會提到一個架構上的解法：殘差連接（Residual Connection，如 ResNet）。

選項解析

- (A) 錯。反向傳播的重點正是「接收上游梯度」，前面層的梯度是後面各層局部梯度相乘的結果，並非各自獨立。
- (B) 錯。這是局部梯度大於 1 時的「梯度爆炸」，與題目的 0.5 相反。
- (C) 錯。題目說的是反向傳播的梯度，梯度直接決定參數更新量，所以一定影響參數更新。
- (D) 錯。訓練框架不會因為梯度小就自動切換精度，這和 VRAM 也沒有關係。
- (E) 對。

對應課程觀念：連鎖律：串聯相乘、並聯相加、反向傳播

三、統計

第 8 題 答案：(B)

(這題沒教，建議學完機器學習再回來看。)

AI 癌症篩檢，罹癌機率高於 threshold 就判陽性並轉介精密檢查。院方認為「漏掉一位真正的病人」遠比「讓健康的人多做一次檢查」嚴重。

- (A) 提高 threshold 以提升 Precision，確保被判為陽性的人幾乎都真的罹癌
- **(B) 降低 threshold 以提升 Recall，接受較多「虛驚一場」的假陽性**

- (C) 以 Accuracy 作為唯一指標，因為 Accuracy 高就代表漏診的人少
- (D) 持續調整 threshold，直到 Precision 與 Recall 同時接近 100% 為止
- (E) threshold 是模型訓練時自動學到的參數，工程師無法事後調整

核心觀念：threshold 由人依應用場景決定；Precision 與 Recall 通常此消彼長。

	預測陽性	預測陰性
實際陽性	TP 成功抓出	FN漏網之魚
實際陰性	FP虛驚一場	TN 正確排除

- **Recall** = $TP / (TP + FN)$ ：真的陽性的人，有找出多少？（是否抓得夠全）
- **Precision** = $TP / (TP + FP)$ ：模型說陽性時，有多少真的陽性？（講的話是否可信）

院方最在意的是 FN（漏網之魚），所以要提高 Recall。做法是**降低 threshold**，稍有嫌疑就抓出來，也就是「寧可錯殺」。代價是 FP（虛驚一場）變多、Precision 下降。這個場景的代價是多做一次檢查，院方可以接受。

選項解析

- (A) 錯。提高 threshold 是「嫌疑很大才抓出來」，會漏掉更多病人（FN 增加），跟院方的優先順序相反。
- (B) 對。
- (C) 錯。癌症篩檢的陽性非常少，資料不平衡，Accuracy 會失真。例如把所有人都判為陰性的「無腦模型」，Accuracy 可以非常高，卻漏掉所有病人。Accuracy 高不代表漏診少。
- (D) 錯。調整 threshold 時，Precision 與 Recall 通常此消彼長，一般無法只靠 threshold 讓兩者同時接近 100%。實務上要依場景決定偏向哪一邊。
- (E) 錯。模型輸出的是機率，threshold 是在模型之外由人設定的，可以事後依需求調整。

對應課程觀念：混淆矩陣、Precision 與 Recall、threshold 權衡與應用場景

第 9 題 答案：(D)

語料中「我喜歡」後面接「貓」7 次、「狗」3 次，標籤都是 one-hot。同事擔心標籤互相矛盾。假設模型容量足夠、以 cross entropy 訓練：

- (A) 矛盾的標籤會讓梯度互相抵銷，模型最後會取中間值，輸出貓、狗各 0.5
- (B) 應先清洗資料，刪掉「我喜歡狗」、只留下多數答案，讓梯度方向一致，模型才能收斂
- (C) 模型會把貓的機率推到 1.0，因為貓佔多數，這樣平均 loss 最低
- **(D) 平均 CE 在預測 (0.7, 0.3) 時最小，模型會學到這個分布**
- (E) 模型的輸出會隨最後讀到的資料，在 (1, 0) 與 (0, 1) 之間來回擺盪，無法收斂

核心觀念：每筆資料是對世界的一次抽樣；one-hot 是抽樣結果，不是目標，目標是抽樣背後的分佈。

設模型對「貓、狗」的預測為 (q_1, q_2) 。10 筆資料的平均損失是

$$\text{平均損失} = 0.7 \cdot (-\log_2 q_1) + 0.3 \cdot (-\log_2 q_2)$$

這正是以 **(0.7, 0.3)** 為目標分布的 **Cross Entropy**。由 $CE = Entropy + KL$ 可知， $KL = 0$ （預測分布 = 目標分布）時 CE 最小，所以模型會學到 (0.7, 0.3)。

模型輸出 (貓, 狗)	平均 CE (bit)
(1.0, 0.0)	∞
(0.9, 0.1)	1.10
(0.7, 0.3)	0.88 (最小)
(0.5, 0.5)	1.00

每一筆資料都說「100%」，模型卻能學到「70%」。兩種標籤是同一個分布的兩次抽樣。

補充：最小值 0.88 bit 就是這份語料的 Entropy。因為語言本身有不確定性，語言模型的 CE 損失降不到 0。

選項解析

- (A) 錯。(0.5, 0.5) 的平均 CE 是 1.00 bit，比 (0.7, 0.3) 的 0.88 bit 高，不是最低點。模型會往資料比例靠，不會取中間值。
- (B) 錯。刪掉「狗」等於人為扭曲資料分布，讓模型以為「我喜歡」後面只能接貓，就像抽樣偏誤。而且不刪資料模型也能收斂到 (0.7, 0.3)。
- (C) 錯。若貓的機率是 1.0，狗的機率就是 0，遇到 3 筆「狗」時每筆損失是 $-\log_2 0 = \infty$ ，平均 loss 反而最大。即使只推到 0.99，狗的每筆損失也高達 $-\log_2 0.01 \approx 6.6$ bit。
- (D) 對。
- (E) 錯。訓練最小化的是所有資料的平均損失，而它的最低點只有一個，就是 (0.7, 0.3)，模型會往那裡收斂，不會在兩個 one-hot 之間來回擺盪。

對應課程觀念：分類 vs. 生成、語言的理想分布、從 one-hot 學習、Loss 最小發生點、語言本身的 Entropy

第 10 題 答案：(A)

用過去一年的信件訓練詐騙偵測模型，驗證集與測試集表現都很好。上線半年後偵測率明顯下降。

- **(A) 這是分布偏移：資料分布和訓練時不同；應持續蒐集新資料並定期重新訓練**
- (B) 測試集表現好代表模型已能泛化到任何未來的資料，所以問題出在先前資料的品質不佳
- (C) 這是典型的過擬合，只要把模型加大、增加訓練輪數，就能解決
- (D) 把上線後的新資料直接併入測試集，讓測試分數重新變高，就能解決問題
- (E) 這是選擇偏誤：當初的資料抽錯了，應把去年的資料重新抽樣、重新訓練

核心觀念：選擇偏誤是「資料抽錯」，分布偏移是「世界變了」。

這個模型當初的開發流程正確，驗證集和測試集表現也好，代表它對「去年的世界」確實學得很好。問題是上線後世界變了：詐騙集團發現成功率降低，就改變詐騙方式。這正是課堂舉的**概念偏移**例子，屬於分布偏移的一種。

對策是 MLOps 的做法：持續監控資料分布、蒐集新資料、定期重新訓練。

選項解析

- (A) 對。
- (B) 錯。測試集只能代表「蒐集資料當時」的分布，無法保證模型能泛化到未來任何資料。這裡的資料品質也沒有問題，否則測試集表現不會好。
- (C) 錯。過擬合的特徵是訓練集表現好、驗證集或測試集表現差。這個模型的驗證集與測試集都表現很好，不是過擬合。而且加大模型、增加訓練輪數通常會讓過擬合更嚴重。
- (D) 錯。測試集是用來**評估**模型的，不會改變模型本身。模型沒有學到新的詐騙手法，偵測率就不會回來。把新資料混進舊的測試集，只會讓評估結果失去意義。
- (E) 錯。選擇偏誤是資料蒐集方式讓某些類型被過度或過少代表。這裡去年的資料並沒有抽錯，是世界變了。重新抽樣去年的資料，仍然學不到今年的新手法。

對應課程觀念：母體與抽樣、選擇偏誤、分布偏移、資料集切分（訓練、驗證、測試集）